

AI개발 수행내역서

과제명	AI기반 항공편 지연 예측모델 개발 및 시각화
담당자	김종록

2026년 6월 24일

1. 개요 및 현황

1.1 추진배경 및 목적

- 장기간 축적된 항공 운항 데이터베이스를 기반으로 하여 인공지능 기반의 자연 예측모델에 대한 수요가 점진적 증대 예상
- 기상 이변 및 공항 인프라 한계로 인한 항공편 지연 및 재해 발생가능성이 높아짐에 따라 체계적이고 정확한 예측이 중요해지고 있는 상황
- 항공 운항 데이터를 분석하고 복잡한 패턴을 학습함으로써, 항공편 지연에 미치는 영향을 보다 정밀하게 예측하고자 함
- 항공편 대상을 시범적 모델로 구축하여 향후 기상 데이터 연동, 노선 배정 등의 다른 업무로 확대하고자 함

1.2 과제 범위

과제구분		내용
AI	AI기반 항공편 지연 예측모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		ROC-AUC, Recall 등 평가지표를 활용한 모델 성능 평가
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템(파이프라인) 구축
		테스트
시각화	실시간 비행정보 연계 및 시각화	실시간 비행정보 연계 모형 구현
		상황관리 대시보드 등 시각화 구현 (Streamlit 웹 프레임워크 활용)
		예측모델 결정 근거 시각화 (XAI 도입)
		테스트
		통합테스트 및 시운전

1.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 데이터 수집 및 관리의 용이성
- 데이콘(DACON) 등에서 이미 검증/구축된 데이터베이스 활용 여부
- 종속변수(지연 여부)에 영향을 미치는 다양한 독립변수(시간, 거리, 항공사 등)에 대한 정보 포함여부를 통한 모델학습의 유용성

○ 예측모델 개발 효율성

■ 수치형 변수와 범주형 변수가 함께 포함되어 있어 전처리, 인코딩, 분류 모델링 전반을 구축하기에 적합한 지 여부

■ 개발된 모델을 프로토타입 화면과 연계하여 실제 예측 흐름까지 확인할 수 있는 지 여부

○ 문제 해결 기여도 및 경제성


■ 예측모델을 통해 공항관리에 상대적 기여도가 높은 지 여부(ex. 지연 저감, 고객 불만 감소 등)

■ 항공 지연문제 선제적 대처를 통한 사회적 비용감소 효과 여부

2) AI 예측 분석모델 적용 대상

기능	수집 데이터	예측모델인자 (독립변수)	AI예측 분석 대상
항공편 지연 예측	- 미 교통통계국(BTS) 운항 정보 데이터 - 항공사, 비행 거리, 출발 예정 시간, 출·도착 공항 정보 등이 포함된 데이터셋 - (25만 건 정답 데이터셋)	- 기본정보 : 운항 월(Month), 출발 - 경로정보 : 비행 거리(Distance), 출발 공항(Origin Airport), 도착 공항(Dest Airport) - 운영정보 : 항공사(Airline)	- 항공편 지연 여부(Delay) 0/1 분류 예측 - 항공사 및 노선별 지연 결정 핵심 요인 분석 - 사용자 입력 기반 예측 결과 제공 및 프로토타입 화면 구현

3) AI 분석모델 구축 프로세스



1. 데이터 수집 (출처 및 구성)

1.1 데이터 출처

- 데이콘(DACON) 공공 데이터셋: 항공편 지연 예측 경진대회 데이터
- 전체 100만 건 데이터 중 학습을 위해 정답값이 존재하는 25만 건의 Labeled 데이터셋 추출 활용

ID	Month	Day_of_Mo	Estimated_Departure_Time	Cancelled	Diverted	Origin_Airport	Origin_Airport	Origin_State	Destination_Airport	Destination_Airport	Destination_State	Distance	Airline	Carrier_Code	Carrier_ID	Tail_Number	Delay
TRAIN_000	4	15			0	0	OKC	13851 Oklahoma	HOU	12191 Texas	419 Southwest	WN	19393 N7858A				
TRAIN_000	8	15	740	1024	0	0	ORD	13930 Illinois	SLC	14869 Utah	1250 SkyWest	AUA	20304 N125SY				
TRAIN_000	9	6	1610	1805	0	0	CLT	11057 North Carolina	LGA	12953 New York	544 American	AA	19805 N103US				
TRAIN_000	7	10	905	1735	0	0	LAX	12892 California	EW	11618 New Jersey	2454 United Air	UA	N595UA				
TRAIN_000	1	11	900	1019	0	0	SFO	14771 California	ACV	10157 California	250 SkyWest	AUA	20304 N161SV				
TRAIN_000	4	13	1545		0	0	EW	11618 New Jersey	DCA	11278 Virginia	199 Republic	AUA	20452 N657RW				Not_Delayed
TRAIN_000	1	20	1742	1903	0	0	EW	11618 New Jersey	BOS	10721 Massachusetts	200 United Air	UA	N66825				Not_Delayed
TRAIN_000	4	20	1815	1955	0	0	ORD	13930 Illinois	MCI	13198 Missouri	403	UA	20304 N110SY				
TRAIN_000	6	13	1420	1550	0	0	BWI	10821	CLT	11057 North Carolina	361 Southwest	WN	19393 N765SW				Not_Delayed
TRAIN_000	6	6	650	838	0	0	LIT	12992 Arkansas	IAH	12266 Texas	374 ExpressJet	UA	20366 N14902				
TRAIN_000	8	13	1730	1844	0	0	DCA	11278 Virginia	PIT	14122 Pennsylvania	204 Republic	AAA	N119HQ				Delayed
TRAIN_000	3	18	600	748	0	0	PHL	14100 Pennsylvania	DTW	11433 Michigan	453 Delta Air	LDL	19790 N3730B				
TRAIN_000	1	12	1015	1145	0	0	CLE	11042 Ohio	DEN	11292 Colorado	1201 Southwest	WN	N8696E				Not_Delayed
TRAIN_000	9	19	615	706	0	0	MAF	13158 Texas	DEN	11292 Colorado	563 SkyWest	AUA	20304 N165SY				Not_Delayed
TRAIN_000	12	18	845	855	0	0	PHX	14107 Arizona	LAS	12889 Nevada	255 Southwest	WN	19393 N705SW				
TRAIN_000	11	18	1355	1532	0	0	PIT	14122 Pennsylvania	LGA	12953 New York	335 SkyWest Airlines Inc.		20304 N262SY				
TRAIN_000	4	5	1111	1412	0	0	SFO	14771 California	SLC	14869 Utah	599 SkyWest	AUA	20304 N144SY				
TRAIN_000	8	10	1400	1624	0	0	EW	11618 New Jersey	JAX	12451 Florida	820	UA	20452 N722YX				
TRAIN_000	8	11	1215	1258	0	0	CRW	11146	ORD	13930	416		20046 N440AW				
TRAIN_000	7	14	1907	2145	0	0	BDL	10529 Connecticut	ATL	10397 Georgia	859 Delta Air	LDL	19790 N962DN				Not_Delayed

1.2 데이터 구성 및 변수 구성

- 종속 변수(Target): Delay (0: 정상 운항, 1: 지연)
- 독립 변수(Features): 수치형 및 범주형 칼럼 6종
 - 비행 및 경로 변수 : 비행 거리(Distance), 출발 공항(Origin_Airport), 도착 공항(Destination_Airport)
 - 시간 및 환경 변수 : 운항 월(Month), 출발 예정 시간(Estimated_Departure_Time)
 - 운영 및 항공사 변수 : 소속 항공사(Airline)

1) 모델 학습 주요 변수 (최종 선택된 Feature)

변수명 (Column Name)	데이터 타입 (Dtype)	변수 설명 (Description)	비고
Delay	object	항공편 지연 여부 (정답이 없는 경우 텍스트 혼재)	Target (예측 대상)
Month	int64	운항 월 (1월 ~ 12월)	주요 특성
Estimated_Departure_Time	float64	출발 예정 시간 (결측치 존재로 실수형, HHMM)	시간대 파생 변수 생성용
Distance	float64	비행 거리 (결측치 존재 시 실수형, 단위: 마일)	주요 특성
Airline	object	소속 항공사명	주요 특성
Origin_Airport	object	출발 공항 (3자리 영문 IATA 코드)	주요 특성
Destination_Airport	object	도착 공항 (3자리 영문 IATA 코드)	주요 특성

2) 모델 학습 제외 변수 (Drop Features)


변수명 (Column Name)	데이터 타입 (Dtype)	변수 설명 (Description)	제외 사유 (제거 근거)
ID	object	고유 식별자	예측과 무관한 식별자
Day_of_Month	int64	운항 일자	패턴 학습의 유의미성 부족
Estimated_Arrival_Time	float64	도착 예정 시간	출발 시간과 강한 다중공선성(중복) 우려
Cancelled / Diverted	int64	결항 / 우회 여부	'지연' 예측 목적과 불일치하여 제외
Origin_Airport_ID 등	int64	공항 및 항공사 고유 ID 숫자	영문 코드 변수와 완전히 중복되는 정보
Tail_Number	object	비행기 등록 번호	범주가 너무 많아 과적합(Overfitting) 유발

2. 데이터 전처리

2.1 중복 데이터 및 결측치 처리

○ Target 변수(Delay)에 결측치가 존재하는 불완전한 행을 모두 삭제하여 정답 라벨이 확실한 완전한 데이터셋 추출.

○ 출발 예정 시간(Estimated Departure Time) 변수의 결측치 처리: 해당 변수는 항공 운항의 핵심이므로 행을 삭제하는 대신 전체 데이터의 중앙값(Median, 12:00) 대체를 통해 데이터 손실을 최소화함.



[결과 도출] EDA 시각화 결과 대부분의 변수에서 결측치가 양호하나, 예측의 핵심이 되는 출발 시간에 일부 결측치가 존재하여 이를 중앙값으로 대체 보완 완료.

2.2 파생 변수(Feature Engineering) 생성

○ 시간대별 패턴 학습 유도

- 원시 데이터: Estimated_Departure_Time (예: 1430 등 연속된 4자리 정수)
- 데이터 가공: HHMM 형태의 데이터에서 분(Minute) 단위를 제외하고 '시간(Hour)' 부분만 추출하여 새로운 파생 변수(Hour) 생성

- 기대 효과: 연속된 4자리 숫자에서는 인공지능이 파악하기 힘든 '특정 시간대(예: 오후/야간)의 지연율 상승 패턴'을 모델이 명확하게 인식하고 가중치를 두어 학습할 수 있도록 유도.

2.3 범주형 인코딩 (One-Hot Encoding)

- 범주형 변수 (Airline, Origin_Airport, Destination_Airport) 인코딩
- 단순한 라벨 인코딩(Label Encoding)을 사용할 경우 알고리즘이 범주형 변수의 숫자를 크기나 순위로 오인할 위험이 존재함. 이를 방지하기 위해 원핫 인코딩(One-Hot Encoding)을 채택하여 범주형 변수를 독립적인 이진 벡터로 변환함.


2.4 수치형 데이터 스케일링

- 수치형 변수 (Month, Hour, Distance) 스케일링
- 시간(1~24)과 거리(수백~수천 단위) 등 수치형 데이터 간 단위 차이로 인한 왜곡을 방지하기 위해 StandardScaler를 활용하여 평균 0, 분산 1로 표준화함.

3. 탐색적 데이터 분석 (EDA)

3.1 HeatMap (상관관계 시각화)


- 변수 간 상관관계 분석을 통해 선형적 패턴을 확인하고자 히트맵 시각화 진행.



[결과 도출] 단순 수치형 변수(시간, 거리) 간의 선형적 상관관계는 0에 가까울 정도로 매우 약하게 나타나며, 범주형 변수가 혼합된 복합적 패턴 학습이 필수적임.

3.2 주요 변수 데이터 분포 (Histogram)

○ 주요 수치형 변수의 분포를 확인하여 이상치(Outlier) 및 데이터 편향성 파악.



[결과 도출] 출발 시간대(Hour)는 아침 6시~8시 구간에 피크를 보이며, 비행 거리(Distance)는 500마일 전후의 단거리 노선이 압도적으로 많음을 확인.

4. 학습 및 모델 평가


4.1 Feature Selection

- 최종 입력 변수 구성
 - 수치형 변수: Month, Hour, Distance
 - 범주형 변수: Airline, Origin_Airport, Destination_Airport
 - 제외 변수: 원본 Estimated_Departure_Time (Hour 파생변수 생성으로 대체)

4.2 베이스라인 모델 성능 비교

본 과제는 '지연(1)'과 '정상(0)'을 구분하는 분류(Classification) 문제이므로, 정확도(Accuracy), 재현율(Recall), ROC-AUC를 핵심 지표로 평가하였음.

비교 모델	정확도 (Accuracy)	재현율 (Recall)	ROC-AUC	비고
Logistic Regression	67.5%	42.1%	0.680	복잡한 비선형 패턴 학습 한계 불균형 데이터로 인해 소수 클래스(지연) 예측 저조
Random Forest	82.1%	5.0%	0.745	
XGBoost (최종 선정)	81.5%	65.0%	0.785	가중치 튜닝을 통한 데이터 불균형 극복 가능



[결과 도출] 여러 알고리즘 중 XGBoost 모델이 가장 넓은 AUC(Area Under Curve) 면적을 보이며 가장 우수한 분류 성능을 나타냄.


4.3 하이퍼 파라미터 튜닝 (XGBoost)

- GridSearchCV 교차 검증을 활용하여 XGBoost의 트리 깊이, 학습률 및 **가중치(scale_pos_weight=5)**를 탐색.
- 튜닝을 통해 소수 클래스(지연) 예측 시 오답에 대한 페널티를 강화하여 모델의 재현율(Recall)을 5%에서 65%로 수직 상승시킴.

4.4 변수 중요도(Feature Importance) 분석

- 모델이 어떻게 지연을 예측했는가? (Explainable AI)

모델 내부의 의사결정 근거를 설명하기 위해 각 변수가 예측에 기여한 중요도를 추출하여 분석함.



[결과 도출] 모델이 어떻게 예측을 수행했는지 확인하는 Feature Importance 분석 결과, 단순 시간이나 거리가 아닌 특정 항공사(Airline) 및 특정 공항 인프라가 지연을 결정짓는 핵심 지표로 나타남. (설명 가능한 AI 시각화)

Streamlit 프로토타입 화면 구성

5.1 모델 예측 웹 시스템 및 UI/UX 고도화

○ 사용자 친화적 대시보드(Dashboard) 구축

비행 조건 설정

공항 및 항공사

출발 공항 (Origin)
애틀랜타 (ATL)

도착 공항 (Destination)
로스앤젤레스 (LAX)

항공사 (Airline)
델타 항공 (Delta)

일정 및 거리

월 (Month)
6

출발 예정 시간 (Hour)
14

비행 거리 (miles)
800

지연 확률 예측하기

항공편 지연 확률 예측 대시보드

이 대시보드는 비행 데이터를 학습한 기계학습 모델의 예측 결과를 제공합니다. 좌측 사이드바에서 비행 조건을 설정하시면, 메인 화면에서 AI의 예측 결과와 분석 근거(시각화 차트)를 확인할 수 있습니다.

좌측 사이드바에서 비행 조건을 설정한 후 '지연 확률 예측하기' 버튼을 눌러주세요.

[프로토타입 화면] 운영자가 출발 공항과 시간대 등을 입력하면, 백그라운드의 AI 모델이 실시간으로 지연 확률과 핵심 원인을 대시보드에 표출.

- Streamlit을 활용하여 운영자가 실시간으로 출발/도착 공항, 항공사, 비행 시간 등을 조작할 수 있는 웹 기반 대시보드 개발 완료.

- 조건 선택창 한글화: 영문 코드(ATL, DFW 등) 대신 직관적인 한글명('애틀랜타', '댈러스/포트워스')으로 선택할 수 있도록 매핑 딕셔너리 적용.

- 3단 탭(Tabs) 화면 설계: 가독성을 극대화하기 위해 메인 화면을 [실시간 예측 결과], [AI 원인 분석], [데이터 및 모델 정보] 세 가지 탭으로 분리 구축.

Streamlit 프로토타입 화면 구성

5.2 국소적 해석(Local Explanation) 기반 원인 시각화 (XAI)


- 예측 결과 알림 : 인공지능이 도출한 '지연 확률' 수치를 직관적 알림창(위험/주의/정상)과 함께 실시간

표출.

- 원인 시각화 차트 : 전체 학습 데이터(Global) 기준이 아닌, 사용자가 방금 선택한 6가지 조건(Local) 내에서만 필터링하여 지연에 가장 결정적인 영향을 미친 요인을 동적 막대그래프로 시각화.




- 자동 텍스트 브리핑 : 데이터 분석가가 아니더라도 쉽게 이해할 수 있도록 가장 큰 원인을 자동 추출하여 "가장 민감하게 반응한 핵심 요인은 [Month(운항 월)] 입니다." 와 같은 포맷으로 읽어주는 동적 알림 기능 탑재.



Streamlit 프로토타입 화면 구성

- 데이터 및 알고리즘 명세 공개 : 시스템의 신뢰성 확보를 위해, AI 학습에 사용된 원본 데이터셋의 출처(미 교통통계국) 및 피쳐 구성표와 함께, 백그라운드에서 구동 중인 XGBoost 모델의 성능 평가 지표(Recall 등)를 투명하게 조회할 수 있는 백과사전 기능을 탑재.



한계점 및 개선 방향

6.1 연구 한계점 및 개선 방향


○ 기상 데이터(Weather Data) 부재의 한계

- 항공편 지연의 가장 치명적인 요인 중 하나인 '기상 악화(눈, 폭우, 태풍 등)' 데이터가 현재 모델의 독립 변수에 포함되어 있지 않음.
- 강설량, 풍속 등의 외부 환경 데이터가 없다 보니 특정 시점의 돌발적인 대규모 지연 사태를 완벽하게 예측하는 데 한계가 존재함.
- **개선 방향:** 향후 실무 도입 시, 기상청(API) 실시간 날씨 데이터와 연동하여 날씨 변수(Temperature, Wind Speed, Precipitation)를 모델에 추가 주입함으로써 예측 성능을 비약적으로 끌어올릴 수 있음.

○ 데이터 불균형(Class Imbalance)의 한계

- 실제 항공 운항 특성상 대부분이 정상 운항(0)이고 지연(1)은 극히 일부이므로 본질적인 데이터 불균형이 존재함.

데이터 불균형: 지연 vs 정상 운항 비율



[데이터 불균형] 전체 운항 중 지연은 약 20% 내외로, 압도적인 정상 운항 데이터에 모델이 편향될 수 있음.

- 본 연구에서는 XGBoost의 가중치 부여 방식으로 상당 부분 극복하여 재현율(Recall)을 확보하였으나, 오탐지 비율이 존재함.
- **개선 방향:** 향후 SMOTE 등 고급 오버샘플링(Over-sampling) 기법을 병행하거나, 모델 앙상블 기법을 고도화하여 정밀도(Precision)와 재현율(Recall) 밸런스를 최적화해야 함.