

2025년도 ML 모델 개발 과제
AI개발 수행내역서

과제명	항공 사고에서 사망자 수에 영향을 미치는 요인 분석
담당자	김OO

2025년 10 월 17 일

1. 사업과제 : 항공 사고에서 사망자 수에 영향을 미치는 요인 분석

2. 개요 및 현황

2.1 추진배경 및 목적

- 항공 사고는 발생 빈도는 낮지만 피해는 매우 크다:사망자 수를 줄이기 위해서는 어떤 요인이 가장 큰 영향을 주는지 파악하는 것이 필수
- 사망자 예측 모델을 구축하고 정확도 향상:항공 데이터는 탑승객 수, 승무원 수, 탑승구성 비율 등 변수들 간 상호작용이 존재
- 변수 영향력 분석 및 해석 가능한 결과 도출 → 안전 정책 활용

2.2 과제 범위

과제구분		내용
AI	AI 기반 비행기 사고 사망자 정밀 예측	항공 사고 원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		RMSE, MAE 등 평가지표를 활용한 모델 성능 평가
		프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	사망자 추이 및 위험 요인 실시간 시각화	항공기 사고 관련 외부 데이터(예: 지역 정보, 날씨 등) 연계(선택)
		상황관리 대시보드 등 시각화 구현
		예측모델 시각화
		테스트
		통합테스트 및 시운전

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터의 신뢰성과 가용성

- 항공 사고 관련 공식 기관(ICAO, NTSB 등)에서 수집된 데이터 사용
- 사고 일자, 탑승 인원, 사망자 수 등 **정량적·구조화된 데이터 확보 가능 여부**
- 결측치 및 오류 데이터를 정제할 수 있는 충분한 정보 존재 여부


○ 예측 가능성과 문제의 명확성

- "사망자 수 예측"이라는 **목표 변수가 명확하고 측정 가능**
- 탑승 인원, 사고 조건 등의 독립변수가 존재하여 **모델링 가능성이 높음**
- 기존 단순 통계만으로는 설명되지 않는 비선형 패턴 존재 → **AI 모델 적용 가치가 높음**

2) AI 예측 분석모델 적용 대상

적용대상 (예측 목표)	AI예측 분석 대상 종속 변수 (Y)	예측모델인자(주요 독립변수)
항공 사고 사망자 예측	사망자 수 (Fatalities) (명 단위 정량 수치)	- 항공기 정보: 탑승객 수(Aboard Passengers), 승무원 수(Aboard Crew), 총 탑승(Aboard) - 사고 관련 특성: 사고 유형, 사고 위치(도시/국가), 사고 발생 시각(연/월/시간) - 피해 규모 정보: 부상자 수, 지상 사망자 수 - 기타 요인: 항공사, 항공기 종류, 비행 목적(군용/민간)
항만 자원 수요 추정	사고 심각도 등급 (예: 사망자 수 기반 레벨 분류 또는 다중 클래스)	- 항공기 정보: 기종, 제조사, 제작년도, 탑승 규모 - 비행 조건: 비행 목적, 국내/국제선, 비행 거리 - 환경 요인: 사고 발생 국가/지역, 기상 조건(선택), 계절 - 이력 기반: 항공사 사고 이력, 과거 사고 빈도

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집

1.1 데이터 출처

Airplane Crash Data Since 1908(1908년 이후 비행기 사고 데이터) from 1908-2019.

출처 : <https://www.kaggle.com/datasets/cgurkan/airplane-crash-data-since-1908>

1.2 데이터 구성 및 변수 구성

1) 데이터 구성

구분	포함 컬럼	설명
① 사고 기본 정보	Date, Time, Location	사고 발생 시점 및 장소
② 항공사/운항 정보	Operator, Flight #, Route	항공사, 운항편명, 경로
③ 항공기 정보	AC Type, Registration, cn/ln	기종, 등록번호, 기체번호
④ 탑승 정보 (Input)	Aboard, Aboard Passangers, Aboard Crew	탑승자 수, 승객수, 승무원수
⑤ 사고 결과 (Output)	Fatalities, Fatalities Passangers, Fatalities Crew, Ground	사망자 수(전체/승객/승무원), 지상 사망자
⑥ 사고 설명 (텍스트)	Summary	사고 발생 상황 설명 (자연어)

2) 종속 변수


컬럼	설명
Fatalities	전체 사망자 수 (회귀 예측의 핵심 Target)

3) 독립 변수

변수	설명
Aboard	총 탑승 인원
Aboard Passangers	승객 수
Aboard Crew	승무원 수
Fatalities Passangers	사망자 관련 변수 → 모델 입력 시 중복/누설 가능성
Fatalities Crew	
Ground	지상 사망자 수

1. 데이터 분석

2.1 상관관계를 고려한 Heatmap 시각화



○ 히트맵 변수별 분포를 통해 정규분포 여부, 데이터 변환 필요성 및 변수 간 관계를 유추

○ 비행기 사고로 인한 사망자 수 예측 모델링을 위한 대상 설정 : Fatalities [사망자 수]

○ 사고 규모와 사망자 수에 영향을 미치는 요인 분석

(1) 매우 높은 상관관계 ($r > 0.7$)

■ Aboard ↔ Aboard Passangers (0.99)

Fatalities ↔ Fatalities Passangers (0.99)

위 변수는 논리적으로 동일 구조를 가진 변수이며,

동시에 사용 시 다중공선성 위험이 존재한다.

→ 모델 구성 시 중복 변수 제거가 필요

■ Aboard ↔ Fatalities (~0.74)

총 탑승 인원이 많을수록 사망자가 많아지는 경향이 매우 뚜렷하다.

→ 사고 규모 자체가 높은 사망률의 핵심 요인임.

(2) 중간 상관관계 ($0.4 < r < 0.7$)

■ Fatalities ↔ Aboard Crew (0.48)

Fatalities ↔ Ground (0.58)

이는 항공기 규모가 클수록 내부뿐 아니라 지상에도 큰 피해를 초래할 가능성을 시사한다.

2.2 탐색적 데이터 분석

1) 결측치 처리

```
# 결측치 처리
for c in ['Aboard Passangers', 'Aboard Crew']:
    if c in df.columns:
        df[c] = df[c].fillna(df[c].median())
df = df.dropna(subset=['Fatalities'])



for c in ['Time', 'AC Type', 'Route', 'Summary', 'Location', 'Operator']:
    if c in df.columns:
        df[c] = df[c].fillna('Unknown')
```

■ 각 컬럼의 처리 방식과 이유

- 컬럼명 : Aboard Passangers, Aboard Crew
- 처리 방식: 중앙값(median)으로 대체
- 이유:
 - > 사고 규모(승객 수)는 극단값이 많고 분포가 비대칭
 - > 평균(mean) 사용 시 이상치 영향 큼
 - > 중앙값 사용하면 데이터 왜곡 최소화
- 컬럼명 : Fatalities (사망자 수)
- 처리 방식: 결측치가 있는 행은 삭제(dropna)
- 이유:
 - > 이 값이 **예측 대상(Target)**이기 때문
 - > 사망자 수가 없으면 학습 자체가 불가능
- 컬럼명 : Time, AC Type, Route, Summary, Location, Operator
- 처리 방식: 'Unknown' 문자열로 채움
- 이유:
 - > 이 값들은 문자열 또는 범주형 데이터
 - > 단순 삭제하면 데이터 손실
 - > "정보 없음"도 의미 있는 하나의 상태로 간주 가능

○ 그룹별 데이터 분포 (Violin Plot)

- 사용 이유 : 단순히 평균/중앙값만 보는 것이 아니라, 데이터가 어떤 모양으로 퍼져 있는지까지 한눈에 이해할 수 있다



- 그래프 설명

- > 대부분의 사고는 소규모지만, 극소수의 대형 사고가 전체 데이터에 큰 영향을 준다.
- > 사고의 규모(탑승 인원, 사망 인원)는 극단적 분포를 가지며, 이는 모델링 시 이상치 처리가 매우 중요하다는 것을 의미한다.
- > 특히 'Ground'[지상에서 사망한 사람 수]는 매우 희귀하지만 영향력이 엄청난 변수이다.
- > 평균으로 단순 비교하는 방식은 부정확하다. [분포 기반 분석이 필수적으로 보인다.]

○ 데이터 전처리

```
# -----  
# 1) X, y 구성 및 데이터 전처리  
# -----  
target_col = 'Fatalities' # 타겟 컬럼명  
assert target_col in df.columns, f"{target_col} 컬럼이 df에 없습니다."  
  
X = df.drop(columns=[target_col]).copy()  
y = df[target_col].copy()  
  
# 범주형(문자열) 컬럼에 대해서는 빈도 인코딩 적용 (간단하고 안전한 방법)  
cat_cols = X.select_dtypes(include=['object']).columns.tolist()  
for c in cat_cols:  
    X[c] = X[c].fillna('Unknown')  
    freq = X[c].value_counts(normalize=True)  
    X[c + '_freq'] = X[c].map(freq)  
# 원문 텍스트(요약 등)는 임베딩 등 별도 처리 권장 - 여기서는 원문 컬럼 제거  
text_cols = ['Summary', 'Route'] # 필요하면 조정  
for c in text_cols:  
    if c in X.columns:  
        X.drop(columns=[c], inplace=True)  
  
# 남은 결측은 0으로 채움, 숫자 변환  
X = X.apply(pd.to_numeric, errors='coerce').fillna(0)
```

- 전처리 과정

① 타겟 / 피쳐 분리

X = 입력 변수(독립 변수)

y = 예측할 값(사망자 수)

② 빈도 인코딩 (범주형 변수처리)

- Unknown으로 결측치 처리

③ 텍스트 컬럼 제거

④ 수치형 변환 & 결측치 처리

⑤ 스케일링 (StandardScaler)

- 각 변수의 단위 차이 제거

3.2 모델학습 및 학습 시각화

○ 모델 학습


```
# -----  
# 2) RandomForest 학습  
# -----  
rf = RandomForestRegressor(  
    n_estimators=300,  
    max_depth=None,  
    min_samples_split=5,  
    min_samples_leaf=3,  
    max_features='sqrt',  
    oob_score=True,  
    n_jobs=-1,  
    random_state=42  
)  
rf.fit(X_train, y_train)
```

- 본 연구에서는 RandomForestRegressor를 사용하여 사망자 수를 예측하였다.
- 모델의 하이퍼파라미터($n_estimators=300$, $max_depth=None$ 등)를 설정한 후,
전처리된 학습 데이터(X_train , y_train)를 사용하여 `.fit()`메서드로 모델을 학습시켰다.
- 이후 테스트 데이터(X_test)에 대해 `.predict()`를 수행하였고,
마지막으로 R^2 , MAE, RMSE 지표를 통해 모델 성능을 평가하였다.


1. 데이터 학습 및 모델정의

3.1 모델정의 및 컴파일

1) 모델별 R^2 Score 성능 비교 [성능이 가장 낮은 다중선형회귀 제외]





2) 각 모델의 변수 중요도 시각화



3) 독립변수 설정 [변수 중요도에서 결정]

```
# 지정한 컬럼명
requested_X_cols = ['Fatalities Passangers', 'Aboard', 'Aboard Passangers', 'Fatalities Crew']
target_col = 'Fatalities'
```

4) 주요 변수별 시각화 [이미지) 다항회귀]



3.3 모델 예측

○ 예측값 vs 실제값 비교

- 적용 모델 : **XGboost**

- 실제 사망자 수와

예측값 간에 높은

일치도를 보였으며(R^2 기준),

RMSE 및 MAE 또한 낮게

나타나 전반적으로 안정적인

예측 성능을 확인할 수

있었다.

- 실제값과 예측값의 산점도에서 데이터가 대각선 근처에


밀집되어 있어 모델이 전반적인 추세를 잘 학습한 것으로

나타났으며, R^2 및 오차 지표(MSE, MAE)를 통해 예측 정확도가

검증되었다.

○ 모델 최적화 및 학습 결과

최종 모델 : **XGboost**



```
# -----
# 5) 예측 및 평가 (R2, MSE, MAE)
# -----
y_pred = model.predict(X_test_scaled)

r2 = r2_score(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
rmse = math.sqrt(mse)


print("\n=== 평가 지표 ===")
print(f"R2 : {r2:.4f}")
print(f"MSE : {mse:.4f}")
print(f"RMSE: {rmse:.4f}")
print(f"MAE : {mae:.4f}")

# -----
# 6) 시각화: 예측 vs 실제 (산점도)
# -----
plt.figure(figsize=(6,6))
plt.scatter(y_test, y_pred, alpha=0.6)
mx = max(y_test.max(), y_pred.max())
plt.plot([0, mx], [0, mx], 'r--')
plt.xlabel('실제 Fatalities')
plt.ylabel('예측 Fatalities')
plt.title('XGBoost: Actual vs Predicted')
plt.tight_layout()
plt.show()
```

○ 하이퍼 파라미터 튜닝

- 모델은 기본값 대신 `n_estimators=300`, `learning_rate=0.05`, `max_depth=6`, `subsample=0.8`, `colsample_bytree=0.8` 등으로 조정하여

트리 수를 늘리고 학습률을 낮춰 안정성을 확보하면서, 샘플링과 정규화를 통해 과적합을 방지하는 방향으로 하이퍼파라미터를 튜닝하였다.




- XGboost(라인 그래프) : 모델의 예측값(주황색)과 실제값(파란색)이 전반적으로 매우 유사한 패턴을 보이며, 특히 큰 변동 구간에서도 곡선이 거의 겹쳐 모델이 추세를 잘 학습했음을 확인할 수 있다. 일부 피크나 급격한 변화 구간에서 약간의 오차가 있으나, 전체적으로 높은 예측 정확도를 보여준다.

4. 프로토타이핑(화면)


4.1 Streamlit 상호작용 시각화

○ 모델 비교 시각화 페이지 [항공 사고 사망자 예측 대시보드]



- 항공기 사고 데이터 기반으로 사망자 수를 예측하는 AI 모델을 시각적으로 구성하고 분석할 수 있는 통합 플랫폼으로, 사용자는 데이터 확인 → 모델 학습 → 성능 비교 → 시각화까지 모든 과정을 UI로 쉽게 수행할 수 있다.

○ 모델별 학습 및 시각화 화면



- 대시보드 좌측 데이터 필터 기능 제공, 하이퍼파라미터 튜닝 기능 제공
- 각 모델별 선택 학습 후 탭별로 눌러서 시각화 확인 가능

5. 결론

■ 본 연구에서는 항공 사고 데이터 기반으로 사망자 수를 예측하기 위해 다양한 회귀 모델을 비교한 결과, XGBoost가 가장 뛰어난 성능을 보였다.

XGBoost 모델은 $R^2 = 0.9920$ 으로 전체 분산의 99% 이상을 설명하며, RMSE 2.5993, MAE 0.8197로 오차 또한 가장 낮게 나타났다.

이는 실제 사망자 수를 매우 정밀하게 예측할 수 있음을 의미한다.

결론적으로, 탑승객과 직원의 수가 사망 규모와 가장 큰 연관이 있음을 알 수 있었고, 항공기 사고로 인해 내륙에 있는 인명 피해도 큰 영향을 미치는 것을 알 수 있었다.

6. 향후 발전 방향

■ 사망자 수를 예측할 수 있는 데이터 변수가 부족한 점이 아쉬웠다. 이후 추가 데이터를 확보하여, 항공사별 안전 준수에 따른 비행기 사고율 등 좀 더 정밀 데이터를 분석할 수 있도록 연구를 진행할 계획이다. 머신러닝 연구를 진행하면서 좀 더 깊이 있는 인공지능 학습방법을 알게 된거 같다. 다음에는 또다른 주제 혹은 더 큰 방향성을 잡고 사회적으로 가치를 창출할 수 있는 연구를 해보고 싶다.