

2025년도 머신러닝 기반 데이터 분석 과제

AI개발 수행내역서

과제명	AI기반 버섯 독·식용 예측모델 개발 및 시각화
담당자	권OO

2025년 5 월 28 일


AI개발 수행내용

1. 사업과제 : AI 기반 버섯 독·식용 판별 모델 개발 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

- AI의 활용도가 갈수록 확장되고 있으며 이에 따라 **개인의 생활** 기반에서의 기대 수요도 증가할 것으로 예상
- **기후변화**로 인해 외래종이나 새로운 식물이 국내에서 발견되고 있으며, **독버섯으로 인한 사고**도 여름철마다 발생하고 있음



- 본 과제에서는 수많은 동식물 중에 **버섯의 외양별 데이터 분석**으로 **독성 여부를 판단**할 수 있는 시범적 모델을 개발하여 향후 다른 동식물로 확대하고자 함

2.2 과제 범위

과제구분		내용
모델	AI 기반 버섯 독·식용 예측모델 개발	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		Accuracy, Precision, Recall, F1-Score 평가지표를 활용한 모델 성능평가
시각화	모델 평가 및 테스트	예측실행 웹앱 프로토타입 구축(streamlit)
		모델 평가시각화
		테스트

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 편의성: 정부 및 공공기관에서 이미 구축된 데이터베이스 활용 여부
- 모델학습 유용성: 종속변수에 영향을 미치는 다양한 독립변수에 대한 정보 포함 및 적절한 학습 데이터양

○ 예측모델 개발 효율성

- 모델학습 및 평가 과정 간소화를 위한 다른 환경 기초데이터에 비해 변수가 상대적으로 단순한 구조 여부
- 개발된 모델을 통해 다른 환경기초 데이터에 적용가능 여부


○ 기후변화 대응에 대한 기여도

- 예측모델을 통해 기후변화에 따른 동식물 변화에 위험에 대한 사회적 비용감소 효과 여부
- 추가 데이터 수집 가능성(ex: 누구나 접속하여 실시간 데이터 업로드)

2) AI 예측 분석모델 적용 대상

환경관리 기능	수집 데이터	독립변수	종속변수
공공안전 (버섯)	- 아가리쿠스(Agaricus)와 레피오타(Lepiota) 과에 속하는 23종의 아가리버섯에 해당하는 가상표본 8,124건	EDA 보고서를 참고하여 총 23개 변수 중 주요 독립변수 10개를 선정 - 멍(bruises) 여부 - 냄새(odor) - 주름살(gill): color, size - 고리 종류(ring-type) - 포자 자국의 색상(spore-print-color) - 링 위의 줄기/표면(stalk-above-ring): color, surface - 링 아래의 줄기/표면(stalk-below-ring): color, surface	- 독·식용 분류(class: edible=e, poisonous=p)

3) AI 분석모델 구축 프로세스




연구개발 주요 결과물

1. 데이터 수집

오듀본 협회 북미 버섯 현장 안내서(The Audubon Society Field Guide to North American Mushrooms, 1981)에서 발췌한 아가리쿠스(Agaricus)와 레피오타(Lepiota)과 버섯 23종에 해당하는 가상 표본 8,124건

2. 데이터 분석

2.1. 버섯의 특성

	명칭	부가 설명
	갓(cap)	형태와 색상이 다양한 버섯의 상단부로 모자를 닮은 형상
	주름살(gill)	갓의 아랫면. 생식세포인 포자를 생성하는 부분
	줄기(stalk)	버섯의 갓을 지지하는 기둥(stem)
	덮개(veil)	버섯이 자라기 전 초기 단계에서 주름과 줄기를 임시로 보호하는 얇은 막
	턱받이(ring)	갓의 아래에서 줄기를 둘러싼 막. 미성숙한 버섯의 주름살을 감싸고 있다가 갓이 성장하면서 파열된 막(veil)의 흔적
	포자(spore)	일반적으로 대기로 방출된 뒤 기질에 떨어져서 새로운 버섯이 생겨나게 하는 미세한 생식세포.

2.2. 특성별 상세

Feature	분류 값(Value)
갓 모양(cap-shape)	bell=b,conical=c,convex=x,flat=f, knobbed=k,sunken=s
갓 표면(cap-surface)	fibrous=f,grooves=g,scaly=y,smooth=s
갓 색깔(cap-color)	brown=n,buff=b,cinnamon=c,gray=g,green=r,pink=p,purple=u,red=e,white=w,yellow=y
멍(bruises)	bruises=t,no=f
냄새(odor)	almond=a,anise=l,creosote=c,fishy=y,foul=f,musty=m,none=n,pungent=p,spicy=s
주름살 부착부(gill-attachment)	attached=a,descending=d,free=f,notched=n
주름살 간격(gill-spacing)	close=c,crowded=w,distant=d
주름살 크기(gill-size)	broad=b,narrow=n
주름살 색깔(gill-color)	black=k,brown=n,buff=b,chocolate=h,gray=g,green=r,orange=o,pink=p,purple=u,red=e,white=w,yellow=y

줄기 모양(stalk-shape)	enlarging=e,tapering=t
줄기 뿌리(stalk-root)	bulbous=b,club=c,cup=u,equal=e,rhizomorphs=z,rooted=r,missing=?
턱받이 위쪽 줄기 표면 (stalk-surface-above-ring)	fibrous=f,scaly=y,silky=k,smooth=s
턱받이 아래쪽 줄기 표면 (stalk-surface-below-ring)	fibrous=f,scaly=y,silky=k,smooth=s
덮개 타입(veil-type)	partial=p,universal=u
덮개 색깔(veil-color)	brown=n,orange=o,white=w,yellow=y
턱받이 개수(ring-number)	none=n,one=o,two=t
턱받이 타입(ring-type)	cobwebby=c,evanescent=e,flaring=f,large=l,none=n,pendant=p,sheathing=s,zone=z
포자 색깔(spore-print-color)	black=k,brown=n,buff=b,chocolate=h,green=r,orange=o,purple=u,white=w,yellow=y
군집형태(population)	abundant=a,clustered=c,numerous=n,scattered=s,several=v,solitary=y
서식지(habitat)	grasses=g,leaves=l,meadows=m,paths=p,urban=u,waste=w,woods=d

2.3. 판단결과(종속변수)

분류(class)	poisonous=p(독성 있는), edible=e(식용 가능)
-----------	-------------------------------------

- 참고로 식용 가능 여부 판단이 모호한 데이터는 p로 표기되었음

2.4. 데이터 샘플

	A	B	C	D	E	F	G	H	I	J	K	L
1	class	cap-shape	cap-surface	cap-color	bruises	odor	gill-attachment	gill-spacing	gill-size	gill-color	stalk-shape	stalk-root
2	p	x	s	n	t	p	f	c	n	k	e	e
3	e	x	s	y	t	a	f	c	b	k	e	c
4	e	b	s	w	t	l	f	c	b	n	e	c
5	p	x	y	w	t	p	f	c	n	n	e	e
6	e	x	s	g	f	n	f	w	b	k	t	e
7	e	x	y	y	t	a	f	c	b	n	e	c
8	e	b	s	w	t	a	f	c	b	g	e	c
9	e	b	y	w	t	l	f	c	b	n	e	c
10	p	x	y	w	t	p	f	c	n	p	e	e

M	N	O	P	Q	R	S
stalk-surface-above-ring	stalk-surface-below-ring	stalk-color-above-ring	stalk-color-below-ring	veil-type	veil-color	ring-number
s	s	w	w	p	w	o
s	s	w	w	p	w	o
s	s	w	w	p	w	o
s	s	w	w	p	w	o

S	T	U	V	W
ring-number	ring-type	spore-print-color	population	habitat
o	p	k	s	u
o	p	n	n	g
o	p	n	n	m
o	p	k	s	u

3. 탐색적 데이터 분석

3.1. 데이터 요약

- 8,124 rows x 23 columns 으로 구성
- 데이터 타입: Categorical(분류)

3.2. 데이터 전처리

- 결측치 없음(Missing cells: 0)
- 중복 데이터 없음(Duplicate rows: 0)
- 분산(Distinct)이 0인 변수는 제외(정보량 Zero)

veil-type	
Categorical	
Constant	
Distinct	1
Distinct (%)	< 0.1%
Missing	0
Missing (%)	0.0%
Memory size	507.9 KiB

- 종속변수(class) 컬럼을 원-핫 인코딩 대상에서 제외하고자 숫자로 변경 처리
- 분류 데이터 원-핫 인코딩 처리 필요(object → bool)

```
# 2. 데이터 전처리
df = df.dropna() # 결측치 제거
df = df.drop_duplicates() # 중복 제거
df = df.drop(columns=['veil-type']) # 'veil-type' 열 제거 (모든 값이 'p'로 동일)
df['class'] = df['class'].map({'p': 1, 'e': 0}) # 종속변수 one-hot 인코딩 제외
df_encoded = pd.get_dummies(df, drop_first=True) # 원-핫 인코딩
df_encoded.head()
```

▶ 시행착오를 거쳐 데이터의 분류값을 숫자로 변환함으로써 원-핫 인코딩 처리를 배제함

3.3. 독립변수(X) 선택

- 종속변수(class)와 연관성이 높은 10개 특성 선택




그림 9 변수간 상관관계 Heatmap

○ 연관성이 높은 10개 특성:

- 멍(bruises) 여부
- 냄새(odor)
- 주름살(gill): color, size
- 고리 종류(ring-type)
- 포자 자국의 색상(spore-print-color)
- 링 위의 줄기/표면(stalk-above-ring): color, surface
- 링 아래의 줄기/표면(stalk-below-ring): color, surface

4. 모델 정의 및 학습

3.1 모델 정의 및 최적화

○ RandomForest 분류 모델 선택 및 최적 파라미터 도출

```
# 하이퍼파라미터 튜닝을 위해 GridSearchCV 사용
param_grid = {
    'n_estimators': [50, 100, 150],      # 트리 개수 증가
    'max_depth': [8, 12, 16],           # 트리 최대 깊이 증가
    'min_samples_split': [2, 5, 10],     # 노드 분할 최소 샘플 수
    'min_samples_leaf': [1, 2, 4],      # 리프 노드 최소 샘플 수
}

rf_model = RandomForestClassifier(random_state=42, n_jobs=-1) # n_jobs=-1: 모든 CPU 코어 사용
# 교차 검증 cv=3 : 훈련 데이터를 3개의 FOLD(묶음, Class)으로 나누어서 두개를 훈련, 나머지는 검증 용도로 활용
grid_search = GridSearchCV(estimator=rf_model, param_grid=param_grid, cv=3, scoring='accuracy')
grid_search.fit(X_train, y_train)

# 최적의 파라미터 출력
print("\nBest Parameters:", grid_search.best_params_)
```

```
Best Parameters: {'max_depth': 12, 'min_samples_leaf': 1, 'min_samples_split': 2, 'n_estimators': 50}
```

○ 기본 vs 최적 파라미터 성능 비교

```
# STEP 1. 기본 하이퍼파라미터 사용
# model = RandomForestClassifier(random_state=42) # 0.2s
# STEP 2. 하이퍼파라미터 조정
model = RandomForestClassifier(max_depth=12, max_features='sqrt', n_estimators=50,
                               min_samples_leaf=1, min_samples_split=2, random_state=42,
                               n_jobs=-1) # 0.1s
model.fit(X_train, y_train)
```

```
► Accuracy: 1.0
► Classification Report:
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	842
1	1.00	1.00	1.00	783
accuracy			1.00	1625
macro avg	1.00	1.00	1.00	1625
weighted avg	1.00	1.00	1.00	1625

- 두 파라미터 세트의 평가결과 성능지표에서의 차이는 없으나 **실행 속도** 면에서 차이가 보였음.

기본 = 0.2s vs 최적 = 0.1s

3.2 모델학습 및 평가

○ 모델학습

- 훈련/테스트 데이터는 8:2 비율로 분할 수행
- 모델 훈련시 특성 변경에 따른 **중요 특성 변화 실험**을 수행

○ 모델학습 특성(X) 변경 비교 실험

- 모델학습시 특성 선택에 따라 중요도 순위에 차이가 생김(모델성능 차이는 없음)
- 종속변수(y)와의 상관계수(correlation coefficient)가 높으면 모델이 예측하는데 있어 중요할 수도 있지만, 반드시 그렇지는 않을 수 있으므로 실험을 통해 최종 예측 변수를 추출함.
- 예측 변수는 프로토타입 화면에서 예측실행시 입력 파라미터로 정의

☑ 실험 1. EDA 기반으로 선정한 10개 특성으로 모델학습

- 정보 가치가 없는 veil-type을 제외한 모든 특성을 사용하여 최종 훈련하여 특성 중요도를 확인하고, 최종적으로 [그림 15]로부터 **예측 변수**를 선택(5%↑, 7개)하여 최종 훈련 진행.

odor ~ stalk-surface-below-ring = 74%




그림 14 EDA 기반으로 선정한 10개 특성 선택 훈련

☑ 실험 2. 모든 특성(veil-type 제외)으로 모델학습





그림 15 모든 특성 훈련(veil-type제외)

☑ 실험 3(final). 모든 특성(veil-type 제외)으로 모델학습

- 실험 2 결과로부터 예측 변수를 선택(5% ↑, 7개)하여 최종 훈련 진행.




○ 모델 평가

- 환경변수 변경에도 정확도 1.0으로 일관된 성능을 보임
- 양질의 데이터셋으로 인한 영향으로 추측

```
▶ Accuracy: 1.0
▶ Classification Report:
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	842
1	1.00	1.00	1.00	783
accuracy			1.00	1625
macro avg	1.00	1.00	1.00	1625
weighted avg	1.00	1.00	1.00	1625


- 혼돈 행렬: 정확도 1.0으로 예측 오답이 Zero 임



○ 데이터 상관관계 Heatmap

- 데이터간 상관관계가 0.5가 넘는 특성이 보임(다중공선성 처리 필요?)

veil-color : gill-attachment 0.84 / stalk-root : spore-print-color 0.72 등



5. 프로토타이핑(화면)

5.1 모델예측

- 모델예측의 중요 특성 7개를 활용하여 예측테스트 화면



버섯 독·식용 예측모델 개발

예측하기 평가시각화

냄새(odor)

☐ almond ☐ anise ☐ creosote ☐ fishy ☐ foul ☐ musty ☐ none ☐ pungent ☒ spicy

포자 색깔(spore-print-color)

☐ black ☒ brown ☐ buff ☐ chocolate ☐ green ☐ orange ☐ purple ☐ white ☐ yellow

주름 크기(gill-size)

☐ broad ☒ narrow

링 타입(ring-type)

☐ flaring ☒ large ☐ none ☐ pendant

군집형태(population)

☐ abundant ☒ clustered ☐ numerous ☐ scattered ☐ several ☐ solitary

턱받이 위쪽 줄기 표면(stalk-surface-above-ring)

☐ fibrous ☒ scaly ☐ silky ☐ smooth

턱받이 아래 줄기 표면(stalk-surface-below-ring)

☐ fibrous ☒ scaly ☐ silky ☐ smooth

위의 항목을 선택하여 버섯의 특성을 입력하세요.

예측하기

예측결과: 식용 가능한 버섯입니다.

4.2 모델평가 시각화

○ 데이터셋을 로드하여 예측을 수행한 평가 결과 시각화 화면

예측하기 평가시각화

아래는 테스트 데이터셋에 대한 모델의 평가 결과입니다.

정확도, 분류 보고서, 혼동 행렬, 특징 중요도를 확인할 수 있습니다.

정확도(Accuracy):

100.00%


분류 보고서(Classification Report):

	precision	recall	f1-score	support
0	1.0000	1.0000	1.0000	783.0000
1	1.0000	1.0000	1.0000	842.0000
accuracy	1.0000	1.0000	1.0000	1.0000
macro avg	1.0000	1.0000	1.0000	1,625.0000
weighted avg	1.0000	1.0000	1.0000	1,625.0000

혼동 행렬(Confusion Matrix)

	Pred_Poisonous	Pred_Edible
Actual_Poisonous	783	0
Actual_Edible	0	842

특징 중요도(Feature Impotance)



6. 결론 및 제안

- 실질적인 서비스 제공을 위한 모델 개발을 위해서는 **현지**의 동식물 상세 데이터가 필요
- **일반 사용자**의 활용 유도 방안
 - 불편한 UI 입력이 아닌 **사진(또는 카메라)**을 이용한 **편리한 인터페이스**를 제공
 - **위치 정보** 활용: GPS 정보를 이용하여 사용자가 위치한 지역에서 발견될 가능성이 높은 버섯 종류를 추천하고, 해당 버섯의 독성 여부를 예측하는 기능을 추가
- 모델 개선 및 확장 방안
 - **다른 동식물로 확장**시 전문가의 자문을 받아 양질의 데이터를 학습시킴으로써 모델의 성능을 높이고
 - 위험한 동식물에 대한 **경고** 기능을 추가 (예를 들어 독버섯 섭취시의 증상과 조치 방법)