

2025년도 Wearable Device 사용 Dataset 분석 과제

AI개발 수행내역서

과제명	AI기반 정신건강 예측모델 개발 및 시각화
담당자	이OO

2025년 3 월 18 일

AI개발 수행내용

사업과제 : Wearable Device Dataset 분석 AI기반 정신건강 예측모델 개발 및 시각화

📌 순서

- ① 프로젝트 개요
- ② 데이터 분석 및 전처리 과정
- ③ 모델학습 및 최적화 과정
- ④ 결과 시각화 및 평가
- ⑤ 데이터 프로파일링 리포트

1. 개요 및 현황

2.1 추진배경 및 목적

- 전 세계적으로 **정신건강 문제가 중요한 공중보건 이슈**로 부각 되고 있으며, WHO에 따르면 전 세계 인구의 약 13%가 정신건강 장애를 경험하고 있음.
- 웨어러블 기기의 **대중화로 심박 수, 수면 패턴, 신체 활동량 등 생체데이터의 지속적 수집**이 가능해졌으며, 이러한 데이터는 정신건강 상태와 관련이 있음.
- 본 프로젝트는 웨어러블 **디바이스에서 수집된 생체데이터를 활용**하여 AI 기반 **정신건강 예측모델을 개발하는 것을 목적으로 함.**
- 이를 통해 **정신건강 상태를 조기에 감지**하고 적절한 개입이 가능하도록 지원함.
- 전문적인 정신건강 서비스 접근이 어려운 환경에서 효과적인 스크리닝 도구를 제공하고자 함.
- 정신건강 문제의 조기 발견과 예방을 촉진하여 **삶의 질 향상과 사회적 비용 절감**에 기여 하는 것을 목표로 함.

2.2 과제 범위

과제구분		내용
AI	AI기반 건강예측모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		Accuracy 등 평가지표를 활용한 모델 성능 평가
		Streamlit 활용 프로토타입 활용
		예측모델 웹기반 시스템 구축
		테스트

2.3 과제 추진 방법


1) 구축 대상 선정 기준

- 장기간 축적된 웨어러블 디바이스 데이터를 기반으로 인공지능 정신건강 예측모델에 대한 수요가 점진적으로 증가
- 정신질환 증가로 인해 조기 건강 진단 및 맞춤형 건강 관리 서비스의 필요성이 확대
- 기존의 단순 데이터 제공 방식을 넘어 AI 기반의 정밀 분석과 직관적인 시각화를 통해 사용자 친화적인 건강 예측 시스템 구축
- 신체정보 분석모델을 시범적으로 개발하여 향후 운동 추천, 스트레스 관리, 만성 정신질환 모니터링 등으로 확장하고자 함

2) AI 예측 분석모델 적용 대상

구분	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
웨어러블 데이터	- 심박수(BPM) 데이터 - 수면시간 데이터 - 기분평가, 신체 활동 단계가 포함된 데이터셋	💡 심박수(사용자의 분당 심박수(BPM)) 💡 수면시간(사용자가 밤에 잔 시간) 💡 신체활동단계(사용자가 하루에 걸은 총 걸음 수) 💡 기분 평가(1~10점 척도로 자기 보고한 기분 평가)	📊 - 정신건강 문제예측 📊 - 심박수(BPM), 수면시간, 신체 활동 단계, 기분 평가 등의 상관관계 분석

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집

- Wearable Device 측정 데이터(엑셀) : 2024년 10월의 데이터

(<https://www.kaggle.com/datasets/soumitradas1/mental-health-prediction-using-wearable-dataset/data>)

	A	B	C	D	E
1	Heart_Rate	Sleep_Dural	Physical_Act	Mood_Ratir	Mental_Health_Condition
2	98	7.425124	13760	5	1
3	111	9.457572	11455	9	0
4	88	4.037103	9174	8	1
5	74	8.864101	12612	1	1
6	102	9.690217	3923	9	0
7	67	4.547954	12446	5	1
8	80	4.968686	4239	9	1
9	98	9.764478	4865	9	0
10	117	7.225241	9229	3	0
11	78	4.08518	10890	8	1
12	82	5.545792	5566	7	1
13	70	6.699662	7595	7	1
14	70	8.157453	13218	2	1
15	83	8.398962	6609	2	1
16	112	9.972529	4213	2	0
17	95	5.725067	6108	2	1
18	99	7.229321	2783	4	0
19	83	7.199941	11158	7	0
20	62	6.433872	9294	2	1
21	81	5.014971	6830	5	1
22	112	9.864739	6831	7	0

- ✔ Heart_Rate_BPM: 사용자의 분당 심박수(BPM).
- ✔ Sleep_Duration_Hours: 사용자가 밤 동안 자는 시간.
- ✔ Physical_Activity_Steps: 사용자가 하루에 걷는 총 걸음 수.
- ✔ Mood_Rating: 1~10점 척도로 보고한 기분 평가 .
- ✔ Mental_Health_Condition: 1은 정신 건강 문제에 대한 높은 위험을 나타내고 0은 위험이 없음을 나타내는 이진 대상 변수.

2.1 시각화한 데이터 분석이 필요한 이유

- EDA를 할 때 히스토그램과 히트맵을 통해 중요한 정보를 얻을 수 있어 히스토그램으로 각 변수의 분포를 살펴보고 정규분포인지 아닌지 확인한다. 만약 분포가 한쪽으로 치우쳐 있다면 로그변환 같은 데이터 변환이 필요한지 판단하고 히트맵을 통해 변수들 간의 상관관계를 파악해서 어떤 변수들이 서로 관련이 있는지 유추할 수 있다. 이러한 과정이 모델링 전에 데이터를 이해하는 핵심 단계로 작용한다.

2.2 탐색적 데이터 분석

- 결측치 및 중복값 통계
 - 결측치 및 중복값 통계 분석 내용 기입
- 데이터 전처리

Overview

Alerts1

Reproduction

Dataset statistics

Number of variables	5
Number of observations	10000
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	390.8 KiB
Average record size in memory	40.0 B

Variable types

Numeric	4
Categorical	1


- 데이터셋에는 총 5개의 변수가 있으며, 10,000개의 관측치(행)로 구성되어 있다.
- 결측값(Missing cells)은 존재하지 않으며, 데이터의 완전성이 유지되고 있다.
- 중복된 행(Duplicate rows)도 없어서 데이터가 중복 입력되지 않았다.
- 데이터는 총 390.8KB의 메모리를 차지하며, 평균적으로 한 레코드당 40.8B를 사용한다.
- 변수 타입은 4개의 숫자형(Numeric) 변수와 1개의 범주형(Categorical) 변수로 구성되어 있다.
- (1개의 범주형 변수는 '정신건강이 좋을 가능성=1, 나쁠 가능성=0')

- 주요 변수별 데이터 분포(Histogram)
 - 주요 변수별 데이터 분포 분석 결과 기입

Heart_Rate_BPM

Real number (R)

Distinct	60	Minimum	60
Distinct (%)	0.6%	Maximum	119
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	89.822	Memory size	78.2 KiB




- 수면 지속 시간 변수는 총 60개의 고유한 값을 가지며, 전체 데이터 중 해당 값이 차지하는 비율은 0.6%이다. 누락된 값(Missing), 무한대(Infinite), 0(Zeros), 음수(Negative) 값이 전혀 없다.
- 데이터의 평균(Mean)은 6.9785, 최소값(Minimum)은 4.0003, 최대값(Maximum)은 9.9988로 나타난다.
- 변수의 전체 메모리 사용량은 78.2KiB이며, 데이터가 고르게 분포되어 있는 것으로 보인다.

Sleep_Duration_Hours

Real number (R)

Unique

Distinct	10000	Minimum	4.000317
Distinct (%)	100.0%	Maximum	9.9988309
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	6.9784946	Memory size	78.2 KiB




- 수면 지속 시간 변수는 총 10,000개의 고유한 값을 가지며, 전체 데이터 중 해당 값이 차지하는 비율은 100.0%이다. 누락된 값(Missing), 무한대(Infinite), 0(Zeros), 음수(Negative) 값이 전혀 없다.
- 데이터의 평균(Mean)은 6.9785, 최소값(Minimum)은 4.0003, 최대값(Maximum)은 9.9988로 나타난다.
- 변수의 전체 메모리 사용량은 78.2KiB이며, 데이터가 고르게 분포되어 있는 것으로 보인다.

Physical_Activity_Steps

Real number (R)

Distinct	7130	Minimum	1000
Distinct (%)	71.3%	Maximum	14998
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	8061.812	Memory size	78.2 KiB




- 일일 걸음 수 변수는 총 7130개의 고유한 값을 가지며, 전체 데이터 중 해당 값이 차지하는 비율은 71.3%이다. 누락된 값(Missing), 무한대(Infinite), 0(Zeros), 음수(Negative) 값이 전혀 없다.
- 데이터의 평균(Mean)은 8061.812, 최소값(Minimum)은 1000, 최대값(Maximum)은 14998로 나타난다.
- 변수의 전체 메모리 사용량은 78.2KiB이며, 데이터가 고르게 분포되어 있는 것으로 보인다.

Mood_Rating

Real number (R)

Distinct	9	Minimum	1
Distinct (%)	0.1%	Maximum	9
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	5.0651	Memory size	78.2 KiB



- 기분 평가 변수는 총 9개의 고유한 값을 가지며, 누락된 값(Missing), 무한대(Infinite), 0(Zeros), 음수(Negative) 값이 전혀 없다.
- 데이터의 평균(Mean)은 5.0651, 최소값(Minimum)은 1, 최대값(Maximum)은 9로 나타난다.
- 변수의 전체 메모리 사용량은 78.2KiB이며, 데이터가 고르게 분포되어 있는 것으로 보인다.

3. 데이터 학습 및 모델 정의

First rows Last rows

	Heart_Rate_BPM	Sleep_Duration_Hours	Physical_Activity_Steps	Mood_Rating	Mental_Health_Condition
0	98	7.43	13760	5	1
1	111	9.46	11455	9	0
2	88	4.04	9174	8	1
3	74	8.86	12612	1	1
4	102	9.69	3923	9	0
5	67	4.55	12446	5	1
6	80	4.97	4239	9	1
7	98	9.76	4865	9	0
8	117	7.23	9229	3	0
9	78	4.09	10890	8	1

```
# 1. 데이터 로드 및 캐싱
@st.cache_data
def load_data():
    df = pd.read_csv('dataset/mental_health_wearable_data.csv', encoding='cp949')
    df = df.rename(columns={'Mental_Health_Condition ': 'Mental_Health_Condition'})
    return df

df = load_data()
df.columns = df.columns.str.strip()
print(df.columns)

# 2. 특성 선택
selected_features = ['Heart_Rate_BPM', 'Sleep_Duration_Hours', 'Physical_Activity_Steps', 'Mood_Rating']
X = df[selected_features]
y = df['Mental_Health_Condition']

# 3. 데이터 분할 및 스케일링
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# 4. 최적의 하이퍼파라미터 찾기 (GridSearchCV 실행)
param_grid_rf = {
    'n_estimators': [100, 200],
    'max_depth': [None, 10],
    'min_samples_split': [2, 5]
}
print(param_grid_rf)
rf = RandomForestClassifier(random_state=42)
grid_search_rf = GridSearchCV(rf, param_grid_rf, cv=5, scoring='accuracy')
grid_search_rf.fit(X_train_scaled, y_train)

# 최적의 하이퍼파라미터 터미널에 출력
print("최적의 하이퍼파라미터:", grid_search_rf.best_params_)
```


■ 모델저장, Streamlit UI, 결과 예측, 모델평가

```
# 6. 모델 저장
dump(model, 'model_model.joblib')

# 7. Streamlit UI
st.title('정신 건강 예측 모델')

heart_rate = st.slider('심박수 (BPM)', min_value=40, max_value=200, value=80, step=1)
sleep_duration = st.slider('수면 시간 (시간)', min_value=0.0, max_value=12.0, value=7.0, step=0.1)
physical_steps = st.number_input('일일 걸음 수', min_value=0, max_value=30000, value=5000, step=100)
mood_rating = st.slider('기분 평가 (1~10)', min_value=1, max_value=10, value=5, step=1)

# 8. 결과 예측
if st.button('예측하기'): # 사용자 입력 데이터 변환 및 예측
    user_data = np.array([[heart_rate, sleep_duration, physical_steps, mood_rating]])
    user_data_scaled = scaler.transform(user_data)
    prediction = model.predict(user_data_scaled)
    prediction_proba = model.predict_proba(user_data_scaled)[0][1]

    if prediction[0] == 1:
        st.error(f'정신 건강 문제 위험이 높습니다. (확률: {prediction_proba:.2f})')
    else:
        st.success(f'정신 건강 문제 위험이 낮습니다. (확률: {prediction_proba:.2f})')

# 9. 모델 평가
st.subheader("모델 정확도")
y_pred = model.predict(X_test_scaled)
accuracy = accuracy_score(y_test, y_pred)
st.write(f"Accuracy: {accuracy:.2f}")
```

■ 특성 중요도 시각화

```
# 10. 특성 중요도 시각화
feature_importances = pd.DataFrame({
    'Feature': selected_features,
    'Importance': model.feature_importances_
}).sort_values(by='Importance', ascending=False)

st.subheader('특성 중요도')
fig, ax = plt.subplots()
ax.barh(feature_importances['Feature'], feature_importances['Importance'], color='pink') # 가로 막대그래프
ax.set_xlabel('중요도')
ax.set_ylabel('특성', rotation=90)
ax.set_title('특성 중요도')
st.pyplot(fig)
```



혼동행렬, 히트맵, 모델평가

```
# 11. 혼동 행렬 (Confusion Matrix) 시각화
cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(8, 6))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues", xticklabels=selected_features, yticklabels=y)
plt.title("Confusion Matrix")
plt.xlabel("Predicted Label")
plt.ylabel("True Label")
plt.show()

# 12. 상관관계 히트맵 - Streamlit에 Matplotlib 그래프 표시
st.subheader('상관관계 히트맵')
fig, ax = plt.subplots(figsize=(8, 6))
sns.heatmap(df.corr(), annot=True, cmap='coolwarm', fmt='.2f', ax=ax)
st.pyplot(fig)


# 13. 모델 평가
st.write('모델 정확도:', accuracy_score(y_test, model.predict(X_test_scaled)))
```

결과



- 혼동행렬
- 예측율이 0.66인 결과에 따라 실제 연관성이 있는 데이터가 아닌 것도 많음을 확인

- Heatmap
- Wearable Device Dataset 상관관계



- 정신 건강에 영향을 미치는 요인 분석
- 상관관계 히트맵 분석 요약:
 - 수면 시간 감소와 심박수 증가는 정신 건강 상태와 상관관계가 있어 주요 예측 변수로 활용된다. 'Mental_Health_Condition'은 'Sleep_Duration_Hours'(-0.32)와 'Heart_Rate_BPM'(-0.27)과 가장 강한 부정적 상관관계를 보인다.
 - 모든 특성 변수들은 서로 간에 매우 낮은 상관관계를 보여 다중공선성 문제가 적다.
 - 'Mood_Rating'은 'Mental_Health_Condition'과 약한 양의 상관관계(0.02)를 보이며, 다른 변수들과는 거의 관계가 없다.
 - 'Physical_Activity_Steps'는 'Mental_Health_Condition'과 매우 약한 부정적 관계(-0.01)를 가지고 있다.

● 결론

유의미한 결과를 만들기 위해서 영향력 있는 독립변수를 추가해야 할 것으로 보인다. 예시로, 음주, 흡연 의존도와 빈도 항목도 추가로 고려할 수 있을 것 같다.

정신건강을 예측하기 위해서는 개인이 가지고 있는 환경적인 요소들과 기저질환, 주변인과의 인간관계 등이 많은 부분 작용하기 때문에 기분 평가 외에 질문항목을 더 늘려야 정확도가 상승할 것이다.