

2025년도 개인 과제

AI개발 수행내역서

과제명	AI기반 환율 예측 모델 개발 및 시각화
담당자	정OO

2025년 3 월 19 일

1. 사업과제 : 엔화,위안화,유가에 따른 환율 변동 추이 예측모델 설계 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

- 최근 AI 및 데이터 분석 기술이 발전하면서, 장기간 축적된 환율 데이터를 활용한 인공지능 기반 환율 예측 모델에 대한 수요가 높아질 것으로 예상
- 최근 국제 정세의 불안정성이 심화되면서, 글로벌 환율 변동성이 증가하는 추세이며, 정확한 환율 예측은 무역 및 금융 시장에서 중요한 의사결정 요소가 되고 있음
- 엔화(JPY/KRW), 위안화(CNY/KRW)의 변동이 달러(USD/KRW) 환율에 미치는 영향을 분석하고 학습함으로써, 각국 통화 간의 상관관계를 파악하여 보다 정밀한 환율 예측 모델을 개발하고자 함
- 먼저 달러화를 대상으로 하여 시범적 모델을 구축하여 향후 다른 통화로 확대하고자 함

2.2 과제 범위

과제구분		내용
AI	AI기반 환율예측모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		RMSE, 결정계수 등 평가지표를 활용한 모델 성능 평가
		Streamlit을 통한 예측모델 웹기반 시스템 구축
		테스트

2.3 과제 추진 방법


1) 구축 대상 선정 기준

- 데이터 접근성 및 활용성
 - 데이터 수집 및 관리의 용이성
 - 정부 및 공공기관에서 이미 구축된 데이터베이스 활용 여부
 - 종속변수에 영향을 미치는 다양한 독립변수에 대한 정보 포함여부를 통한 모델학습의 유용성
- 예측모델 개발 효율성
 - 모델 학습 및 평가 과정 간소화를 위한 다른 환경 기초데이터에 비해 변수가 상대적으로 단순한 구조 여부
 - 개발된 모델을 통해 다른 통화 데이터에 적용가능 여부
- 급격한 환율 변동문제 해결 기여도 및 경제성
 - 급격한 환율 변동 문제 예측을 통한 경제적, 사회적 기여 여부
 - 무역문제 해결을 통한 물가안정 효과 여부

2) AI 예측 분석모델 적용 대상

환율예측 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
환율	- 일별 달러화/원화 데이터 - 일별 위안화/원화 데이터 - 일별 엔화/원화 데이터 - WTI(기준유가지수)	- 날짜변수 : 기준일(2025.3.18.)로부터 최근 1년간의 날짜데이터 - 통화변수 : 위안화,엔화의 1년간 변 동데이터	- 달러화(다른 통화의 영향을 받음) - 여러 분석방법(의사결정나무, 다항회귀법,LSTM등)의 정확 도 파악

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집

-주요국 통화의 대원화 환율(2025.3.18.기준)


변수명	2025.03.04	2025.03.05	2025.03.06	2025.03.07	2025.03.11	2025.03.12	2025.03.13	2025.03.14	2025.03.17
원/미국달러	1459.77	1459.61	1456	1441.6	1446.3	1451.5	1457.9	1452	1451.9
원/일본엔	199.72	200.34	200.34	198.84	199.55	200.13	201.01	200.72	200.34
원/중국위안	976.37	973.42	978.26	974.28	980.54	988.29	986	979.86	981.64
원/유로	1529.37	1552.14	1571.24	1555.92	1569.52	1573.57	1591.44	1581.01	1575.6
원/영국파운드	1852.69	1867.56	1877.15	1857.72	1869.85	1869.02	1887.76	1882.52	1880.43
원/캐나다달러	1006.66	1013.89	1016.94	1006.75	1005.84	1005.44	1010.47	1011.14	1006.27
원/스위스프랑	1626.2	1640.37	1634.58	1631.97	1648.58	1648.68	1651.26	1646.91	1644.56
원/호주달러	907.17	916.26	922.52	913.25	910.66	910.6	918.19	918.68	912.74
원/뉴질랜드달러	819.13	827.23	834.29	827.26	825.26	825.98	833.12	832.94	827.51
원/홍콩달러	187.55	187.79	187.35	185.49	186.11	186.85	187.62	186.89	186.82
원/대만달러	44.33	44.49	44.35	43.84	44.04	44.14	44.34	44.11	44.02
원/싱가포르달러	0.42	0.42	0.42	0.42	0.42	0.42	0.42	0.42	0.42
원/인도루피	2.91	2.92	2.93	2.9	2.95	2.96	2.98	2.95	2.91
원/태국바트	42.85	43.32	43.34	42.78	42.89	42.8	43.24	42.95	43.08
원/싱가포르달러	1083.17	1091.04	1094.2	1081.92	1087.53	1088.49	1095.75	1089.84	1086.79
원/인도루피	8.85	8.88	8.93	8.83	8.88	8.88	8.89	8.83	8.84
원/말레이시아링깃	326.62	326.79	328.71	325.6	327.59	328.13	330.36	327.73	327.15
원/필리핀페소	25.26	25.35	25.4	25.15	25.17	25.26	25.48	25.29	25.31

(출처: kosis 국가통계포털 <https://kosis.kr/search/search.do>)

-데이터 규모 : 360개 축적 데이터

2. 데이터 분석

2.1 데이터 상관관계(Heatmap)



- 달러 환율에 영향을 주는 주요 변수중 4가지 주요 지표를 선정하여 분석
- 위안화(CHINA): 달러 환율과 강한 양의 상관관계
- 엔화(JAPAN): 달러 환율과 약한 양의 상관관계
- WTI(국제유가 지수): 달러 환율과 음의 상관관계
- 시간 변수(날짜): 달러화는 강한 상방 압력(우상향 경향)을 보임


2.2 탐색적 데이터 분석

- 결측치 및 중복값 통계
- 결측치 및 중복값 통계 분석 내용 기입

Overview	Alerts 6	Reproduction
----------	----------	--------------

Dataset statistics		Variable types	
Number of variables	5	DateTime	1
Number of observations	235	Numeric	4
Missing cells	13		
Missing cells (%)	1.1%		
Duplicate rows	0		
Duplicate rows (%)	0.0%		
Total size in memory	9.3 KiB		
Average record size in memory	40.5 B		

- 주요 변수별 데이터 분포(Histogram)
- 주요 변수별 데이터 분포 분석 결과 기입




CHINA

Real number (R)

High correlation

Distinct	214	Minimum	184.86
Distinct (%)	91.1%	Maximum	202.38
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	192.33268	Memory size	2.0 KiB




JAPAN

Real number (R)

High correlation

Distinct	230	Minimum	855.38
Distinct (%)	97.9%	Maximum	988.29
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	911.24813	Memory size	2.0 KiB




WTI_Price

Real number (R)

High correlation

Distinct	12	Minimum	69.95
Distinct (%)	5.1%	Maximum	85.35
Missing	1	Zeros	0
Missing (%)	0.4%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	76.691068	Memory size	2.0 KiB



○ 데이터 전처리

	date	USA	CHINA	JAPAN	WTI_Price
0	2024-03-27	1338.60	184.86	883.24	77.25
1	2024-03-28	1345.80	185.57	889.17	77.25
2	2024-03-29	1346.80	185.75	889.48	77.25
3	2024-04-01	1347.40	185.63	890.11	77.25
4	2024-04-02	1347.10	185.68	888.32	77.25
5	2024-04-03	1353.00	186.13	892.69	77.25
6	2024-04-04	1349.10	185.92	889.88	77.25
7	2024-04-05	1346.80	185.88	890.53	77.25
8	2024-04-08	1351.80	186.60	891.37	77.25
9	2024-04-09	1353.60	186.63	891.49	77.25

3. 데이터 학습 및 모델정의

3.1 최적화 모델 찾기

○ 하이퍼 파라미터 튜닝 과정


```
# 하이퍼파라미터 튜닝을 위한 설정
param_dist_rf = {
    "n_estimators": [100, 500, 1000], "max_depth": [3, 5, 10],
    "min_samples_split": [2, 5, 10], "min_samples_leaf": [1, 2, 5],
    "max_features": ["auto", "sqrt", "log2"]
}
param_dist_dt = {
    "max_depth": [3, 5, 10, None], "min_samples_split": [2, 5, 10],
    "min_samples_leaf": [1, 2, 5]
}
param_dist_svr = {
    "C": [0.1, 1, 10, 100], "epsilon": [0.01, 0.1, 1],
    "kernel": ["linear", "poly", "rbf"]
}
param_dist_nn = {
    "hidden_layer_sizes": [(50, 50), (100, 50), (100, 100)], "max_iter": [500, 1000, 2000]
}
```

각 모델별 하이퍼 파라미터 튜닝을 진행하고 학습 및 정확도 평가를 진행

○ 모델별 R² Score 비교

```
# 시각화: 모델별 R2 Score 비교
r2_scores = [result["R2"] for result in results.values()]
model_names = list(results.keys())
```

○ Result



결과 : Random Forest 모델이 결정계수 0.59의 값으로 가장 최적화된 모델임을 확인

3.2 모델생성 및 결과 비교

○ 변수 지정 후 모델 학습 및 테스트

```
# 독립변수(X)와 종속변수(y) 정의
X = data[["date_int", "CHINA", "JAPAN"]] # 날짜(숫자), 중국 환율, 일본 환율
y = data["USA"] # 미국 달러 환율

# 데이터 분할 (80% 학습, 20% 테스트)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, shuffle=False)
```

독립변수를 날짜, 위안화, 엔화로 지정하고 종속변수를 달러환율로 설정

데이터를 8:2로 나누어 학습과 테스트 진행

○ 모델 학습 및 최적의 하이퍼 파라미터 출력

```
# 모델 학습
random_search.fit(X_train_scaled, y_train)


# 최적의 하이퍼파라미터 출력
print("✅ 최적의 하이퍼파라미터:", random_search.best_params_)
```

```
최적의 하이퍼파라미터: {'n_estimators': 100, 'min_samples_split': 2, 'min_samples_leaf': 1, 'max_features': 'log2', 'max_depth': 5}
최적화된 RandomForest 모델 평가
평균 제곱 오차 (MSE): 49.75
결정 계수 (R2): 0.59
```


최적의 파라미터로 훈련시 결정계수 0.59와 MSE 49.75의 값으로 가장 비슷한 결과를 얻음

3.3 모델 예측

○ 예측값 vs 실제값 비교 (WTI 반영하지 않을 때)



○ 예측값 vs 실제값 비교 (WTI 반영할 때)



결과 : 실제 값보다 변동폭이 더 적게 나타나는 것을 확인할수 있음

○ 모델 평가 (WTI 반영할 때)

◆ 평균 제곱 오차 (MSE): 60.04
◆ 결정 계수 (R^2): 0.50

결정계수와 MSE 또한 WTI를 반영했을 때 더 오차가 크게 나타나는 것을 확인

4. 여러 가지 모델 결과 비교

4.1 선형 회귀 모델(Polynomial Regression)

○ 선형 회귀 모델 설정

```
# 2. 다항 회귀 모델 설정
poly_degree = 1 # 선형회귀모델
poly_model = make_pipeline(PolynomialFeatures(degree=poly_degree), LinearRegression())
```

degree=1로 하여 선형회귀모델로 설정

○ 모델 학습 및 평가

학습

```
# 3. 모델 학습 (X_train_scaled → 다항 변환 후 학습)
poly_model.fit(X_train_scaled, y_train)

# 4. 예측 수행
y_pred_poly = poly_model.predict(X_test_scaled)


# 5. 성능 평가 (다항 회귀)
mse_poly = mean_squared_error(y_test, y_pred_poly)
r2_poly = r2_score(y_test, y_pred_poly)

print(f"✅ Polynomial Regression 모델 평가 (degree={poly_degree})")
print(f"💎 평균 제곱 오차 (MSE): {mse_poly:.2f}")
print(f"💎 결정 계수 (R²): {r2_poly:.2f}")
```

평가

```
✅ Polynomial Regression 모델 평가 (degree=1)
💎 평균 제곱 오차 (MSE): 235.22
💎 결정 계수 (R²): -0.95
```

○ 랜덤 포레스트 vs 선형회귀모델 비교 그래프 시각화



선형회귀함수는 시계열 분석에 적합하지 않은 모습을 보임

4.2 다항 회귀 모델(Polynomial Regression)

○ 다항 회귀 모델 설정

```
# 2. 다항 회귀 모델 설정 (degree=2 적용)
```

```
poly_degree = 2 # 다항식 차수 설정
```

```
poly_model = make_pipeline(PolynomialFeatures(degree=poly_degree), LinearRegression())
```

degree=2 터 degree=6까지의 값으로 모델을 설정했을 때, degree=2에서 결정계수가 -4.52로 가장 적합한 모델인 것으로 나타남(3차 이상의 경우 결정계수가 -60이상의 값으로 나타남)

○ 모델 학습 및 평가

학습

```
# 3. 모델 학습 (X_train_scaled → 다항 변환 후 학습)
```

```
poly_model.fit(X_train_scaled, y_train)
```

```
# 4. 예측 수행
```

```
y_pred_poly = poly_model.predict(X_test_scaled)
```

```
# 5. 성능 평가 (다항 회귀)
```

```
mse_poly = mean_squared_error(y_test, y_pred_poly)
```

```
r2_poly = r2_score(y_test, y_pred_poly)
```

```
print(f"✅ Polynomial Regression 모델 평가 (degree={poly_degree})")
```

```
print(f"◆ 평균 제곱 오차 (MSE): {mse_poly:.2f}")
```

```
print(f"◆ 결정 계수 (R²): {r2_poly:.2f}")
```


평가

```
✅ Polynomial Regression 모델 평가 (degree=2)
```

```
◆ 평균 제곱 오차 (MSE): 666.52
```

```
◆ 결정 계수 (R²): -4.52
```

○ 랜덤 포레스트 vs 다항함수 비교 그래프 시각화



결과 : 2024년 11월까지의 더 적합한 모습을 보이나, 최근 30일은 적합하지 않은 모습을 보임

4.3 인공 신경망(Neural network)

○ 인공신경망 모델 생성 및 학습

```
# LSTM 모델 생성
model = Sequential([
    LSTM(50, return_sequences=True, input_shape=(look_back, 1)),
    LSTM(50),
    Dense(1)
])
model.compile(optimizer="adam", loss="mse")


# 모델 학습
model.fit(X_train, y_train, epochs=50, batch_size=16, verbose=1)
```

○ 모델 평가

```
✓ LSTM 모델 평가
◆ 평균 제곱 오차 (MSE): 0.01
◆ 결정 계수 (R2): -0.35
```

MSE의 값은 가장 작게 나오나, 결정계수가 적합하지 않은 수준으로 나타남

○ 실제데이터 vs LSTM 예측 비교 그래프 시각화



결과 : 전체적인 경향은 따라가는 것으로 보이나, 급격한 변화는 반영하지 못하는 것으로 보임

4.4 SVR(Support Vector Regression)

○ SVR 모델 생성 및 학습

```
# 3. SVR 모델 생성 (C, epsilon, gamma 조정)
svr_model = make_pipeline(MinMaxScaler(), SVR(kernel='rbf', C=100, epsilon=0.04, gamma=0.25))


# 4. 모델 학습 (스케일링된 데이터 사용)
svr_model.fit(X_train, y_train)

# 5. 예측 수행 (X_test_scaled 사용)
y_pred_svr = svr_model.predict(X_test)
```

○ 모델 평가

- ✅ Before Rescale: X_train shape = (188, 3), X_test shape = (47, 3)
- ✅ SVR 모델 평가
 - ◆ 평균 제곱 오차 (MSE): 55.51
 - ◆ 결정 계수 (R^2): 0.54

○ 실제데이터 vs LSTM 예측 비교 그래프 시각화



결과 : 결정계수의 값이 가장 크진 않지만, MSE의 값은 적합한 범위(≤ 60)인 것으로 나타남

5. 요약

본 프로젝트는 AI 모델을 이용하여 미국 달러 환율 예측 모델을 구축하는 것을 목표로 진행되었다.

1. 데이터 구성 및 학습 과정

- 독립 변수(Feature): 달러 환율에 영향을 미칠 것으로 예상되는 위안화(CHINA), 엔화(JAPAN), 국제유가(WTI) 최근 1년간 데이터를 사용.
- 데이터 분할: 전체 데이터의 80%를 학습 데이터로, 20%를 테스트 데이터로 설정하여 모델을 학습.
- 모델 비교: 다양한 머신러닝 모델을 적용한 후, 랜덤 포레스트(Random Forest), SVR, 다항 회귀, LSTM 모델을 비교 분석함.
- 하이퍼파라미터 튜닝: 랜덤 서치를 이용하여 각 모델의 최적 하이퍼파라미터를 탐색 후 최적화 진행.

2. 모델 성능 비교

- 랜덤 포레스트(Random Forest) 모델의 결정계수(R^2)가 0.59로 가장 높은 값을 기록.
- 하지만, 최근 정치적 이슈로 인한 달러 인덱스 급변 현상을 반영하지 못해 최근 데이터에서 예측값과 실제값 간의 차이가 발생.
- 다항 회귀(Polynomial Regression)는 MSE 값이 매우 크게 나타났으며, 방향성이 실제와 반대로 나타남.
- LSTM 모델은 MSE가 가장 낮았지만, 급격한 변화를 반영하지 못하여 결정계수(R^2)가 낮게 나타남.

3. 데이터의 한계점 및 개선 방안

- 현재 독립 변수로 위안화, 엔화, 국제유가(WTI)만 사용했으나, 실제 달러 환율에는 물가상승률(CPI), 달러 인덱스(DXY), 기준금리, 실업률 등의 다양한 경제 지표가 영향을 미침.
- 특히, 국제 유가(WTI) 데이터는 매달 14일 기준 선물 가격을 사용하여, 실제 유가 변동성을 반영하지 못할 가능성이 있음.
- 미래 개선 방안:
 - 추가적인 경제 지표(CPI, DXY, 기준금리 등)를 반영하여 독립 변수 확대.
 - 시계열 데이터에 적합한 LSTM 모델을 최적화하여 비선형적인 변화를 더 정확하게 반영할 수 있도록 개선.
 - 실시간 데이터 업데이트 기능 추가하여 최신 환율 변동성을 반영하는 실시간 모델 구축.

4. 결론

본 프로젝트를 통해 과거 데이터를 기반으로 환율 변동을 예측하는 것이 가능하지만, 한정된 독립 변수만으로는 정확한 예측이 어렵다는 점을 확인하였다.

특히, 실제 환율 변동은 다양한 요인이 복합적으로 작용하므로, 보다 많은 경제 지표를 반영한 모델이 필요함을 알 수 있었다.

향후 추가적인 변수를 고려하고, 비선형성을 더 잘 반영하는 최적화된 AI 모델을 적용하는 방향으로 연구를 발전시킬 필요가 있다.