

2025년도 AI 프로젝트
AI개발 및 데이터 분석 수행내역서

과제명	치매 분류에 영향을 주는 변수에 대한 연구
담당자	황 O O

2025년 08월 01일

AI개발 수행내용

1. 사업과제 : 치매 분류에 영향을 주는 변수에 대한 연구 및 머신러닝 모델 개발

2. 개요 및 현황

2.1 추진배경 및 목적

- 걸음걸이 및 라이프로그 데이터를 기반으로 인공지능 기반 치매 예방 예측 모델에 대한 수요가 점차 증가할 것으로 예상됨
- 고령화 사회 진입과 함께 치매 환자가 급증하고 있어, 조기 발견과 예방이 사회적·의료적 중요한 과제로 대두됨
- 일상 생활 속 걸음걸이 패턴 및 활동 데이터를 분석하여 치매 발생 전 조기 변화를 감지하고, 개인 맞춤형 건강 관리를 지원하고자 함
- 시범적으로 걸음걸이 데이터를 활용한 치매 예측 모델을 구축하여, 향후 인지기능 저하 관련 다양한 라이프로그 데이터를 통합한 정밀 예측 시스템으로 확장하고자 함

2.2 과제 범위

과제구분		내용
AI	AI기반 치매 분류모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		평가지표를 활용한 모델 성능 평가
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	실시간 걸음걸이 라이프로그 데이터 연계 및 시각화	환경계측정보 실시간 연계 모형 구현
		상황관리 대시보드 등 시각화 구현 (BI 시각화 도구 활용)
		예측모델 시각화
		테스트
		통합테스트

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 걸음걸이 및 라이프로그 데이터의 수집 및 관리 용이성
- 의료기관, 공공보건기관, 웨어러블 기기 업체 등에서 구축·보유 중인 관련 데이터베이스 활용 가능 여부
- 치매 발병과 연관된 다양한 독립 변수(예: 저활동 MET, 휴식 시간, 비활동 시간등)를 포함하여 분류 모델 학습에 유용한 정보 확보 여부

○ 분류 모델 개발 효율성

- 복잡하지 않은 변수 구조를 갖추어 모델 학습 및 평가 과정이 효율적으로 진행될 수 있는지 여부
- 개발된 치매 예측 모델이 다른 인지기능 관련 데이터셋에도 확장 적용 가능 여부

○ 사회적 기여도 및 경제성

- 예측모델을 통한 조기 치매 위험 탐지로 환자 관리 및 치료 효과 증대 가능성
- 조기 예방 및 관리로 인한 의료비 절감 및 사회적 비용 감소 효과
- 건강관리 효율성을 높여 개인 및 공공 차원의 비용 절감 효과

2) AI 예측 분석모델 적용 대상

대상기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
치매 예방 및 조기 발견을 위한 건강관리 기능	- 일별 걸음 수, 활동 시간, 활동 강도 등 라이프로그 데이터 - 바이오 데이터	- 신체 활동 변수: 하루 걸음 수, 활동 강도, 활동 시간 - 생리 변수: 심박수, 수면 질, 휴식 시간	- 치매 발병 위험도 예측 - 인지 기능 저하 조기 경고 - 개인 맞춤형 건강관리 추천

3) 분류 머신모델 구축 프로세스




그림 1 모델 아키텍처

연구개발 주요 결과물

1. 데이터 수집

- 에코인사이트글로벌 2개월 간 55세 이상 어르신 라이프로그 데이터(엑셀) : 2020년 ~2021년
- 조선대 산학협력단 2개월 간 전력량 데이터(엑셀) : 2020년 ~2021년

1	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
2	EMAIL	activity_ave	activity_cal	activity_cal	activity_class	activity_daily	activity_day	activity_high	activity_inact	activity_inact	activity_low	activity_med	activity_met	activity_met	activity	
3	nia+279@rc	1,28125	196	2251	...	3353	2020-10-2	2020-10-1	0	714	0	201	6	...	0	
4	nia+279@rc	1,25	145	2159	...	2516	2020-10-2	2020-10-2	0	719	0	131	9	...	0	
5	nia+279@rc	1,21875	118	2140	...	1716	2020-10-2	2020-10-2	0	708	1	125	6	...	0	
6	nia+279@rc	1,28125	180	2240	...	2791	2020-10-2	2020-10-2	0	705	0	203	5	...	0	
7	nia+279@rc	1,46875	374	2559	...	5393	2020-10-2	2020-10-2	0	437	0	511	6	...	0	
8	nia+279@rc	1,53125	436	2630	...	6860	2020-10-2	2020-10-2	0	377	0	548	13	...	0	
9	nia+279@rc	1,28125	159	2212	...	2433	2020-10-2	2020-10-2	0	679	0	201	2	...	0	
10	nia+279@rc	1,28125	159	2212	...	2365	2020-10-2	2020-10-2	1	644	1	192	4	...	7	
11	nia+279@rc	1,4375	407	2508	...	7288	2020-10-2	2020-10-2	0	467	0	371	28	...	0	
12	nia+279@rc	1,5	408	2587	...	6368	2020-10-2	2020-10-2	1	438	0	509	11	...	7	
13	nia+279@rc	1,25	191	2224	...	2950	2020-10-3	2020-10-2	0	401	0	265	2	...	0	
14	nia+279@rc	1,28125	154	2233	...	2138	2020-10-3	2020-10-3	0	635	0	208	1	...	0	
15	nia+279@rc	1,1875	74	2075	...	934	2020-11-C	2020-10-3	0	647	0	100	1	...	0	
16	nia+279@rc	1,15625	63	2039	...	776	2020-11-C	2020-11-C	0	634	0	89	0	...	0	
17	nia+279@rc	1,28125	143	2213	...	1947	2020-11-C	2020-11-C	0	678	0	183	2	...	0	
18	nia+279@rc	1,34375	204	2336	...	2767	2020-11-C	2020-11-C	0	699	0	269	3	...	0	
19	nia+279@rc	1,40625	329	2454	...	5611	2020-11-C	2020-11-C	2	685	0	290	17	...	14	
20	nia+279@rc	1,3125	207	2295	...	3362	2020-11-C	2020-11-C	0	727	0	219	7	...	0	
21	nia+279@rc	1,40625	392	2463	...	7154	2020-11-C	2020-11-C	0	533	0	252	48	...	0	
22	nia+279@rc	1,46875	481	2554	...	5810	2020-11-C	2020-11-C	0	503	2	458	13	...	0	
23	nia+279@rc	1,5625	331	2663	...	6410	2020-11-C	2020-11-C	1	627	0	496	20	...	8	
24	nia+279@rc	1,4375	392	2523	...	6306	2020-11-1	2020-11-C	0	411	0	390	23	...	0	
25	nia+279@rc	1,5	442	2616	...	7621	2020-11-1	2020-11-1	0	502	0	464	18	...	0	
26	nia+279@rc	1,46875	372	2531	...	5880	2020-11-1	2020-11-1	0	512	0	418	17	...	0	
27	nia+279@rc	1,25	162	2181	...	2216	2020-11-1	2020-11-1	0	483	1	195	7	...	0	
28	nia+279@rc	1,28125	201	2250	...	3408	2020-11-1	2020-11-1	0	652	1	211	7	...	0	
29	nia+279@rc	1,28125	183	2246	...	2391	2020-11-1	2020-11-1	0	605	0	232	7	...	0	
30	nia+279@rc	1,25	125	2174	...	1770	2020-11-1	2020-11-1	0	717	0	157	3	...	0	
31	nia+279@rc	1,375	311	2407	...	5160	2020-11-1	2020-11-1	0	580	2	285	22	...	0	
32	nia+279@rc	1,34375	242	2334	...	3894	2020-11-1	2020-11-1	0	659	1	255	10	...	0	
33	nia+279@rc	1,28125	186	2241	...	2862	2020-11-2	2020-11-1	0	663	0	187	10	...	0	
34	nia+279@rc	1,28125	181	2230	...	3058	2020-11-2	2020-11-2	0	668	1	205	4	...	0	
35	nia+279@rc	1,34375	257	2359	...	3908	2020-11-2	2020-11-2	2	659	0	260	14	...	13	
36	nia+279@rc	1,3125	186	2278	...	2815	2020-11-2	2020-11-2	0	738	0	241	6	...	0	
37	nia+279@rc	1,4375	251	2447	...	2326	2020-11-2	2020-11-2	0	535	0	440	2	...	0	
38	nia+279@rc	1,34375	287	2370	...	4769	2020-11-2	2020-11-2	0	487	0	320	10	...	0	

그림 2 라이프로그 데이터셋

2. 데이터 분석

2.1 데이터 칼럼 설명 (활동 데이터)

칼럼	데이터 설명
이메일	이메일
Date	요약 날짜
nonwear	미착용 시간
activity_average_met	하루간 평균 MET
activity_cal_active	하루간 활동 칼로리
activity_cal_total	하루간 총 사용 칼로리
activity_class_5min	하루간 5분 당 활동 로그
activity_daily_movement	매일 움직인 거리
activity_day_end	활동 종료 시간
activity_day_start	활동 시작 시간
activity_high	고강도 활동 시간
activity_inactive	비활동 시간
activity_inactivity_alerts	비활동 알람 횟수
activity_low	저강도 활동 시간
activity_medium	중강도 활동 시간
activity_met_1min	하루간 1분 당 MET 로그
activity_met_min_high	하루간 고강도 활동 MET
activity_met_min_inactive	하루간 비활동 MET
activity_met_min_low	하루간 저강도 활동 MET
activity_met_min_medium	하루간 중강도 활동 MET
activity_non_wear	미착용 시간
activity_rest	휴식 시간
activity_score	활동 점수
activity_score_meet_daily_targets	활동 목표달성 점수
activity_score_move_every_hour	매 시간 당 활동유지 점수
activity_score_recovery_time	회복시간 점수
activity_score_stay_active	활동 유지 점수
activity_score_training_frequency	운동 빈도 점수
activity_score_training_volume	운동 강도 점수
activity_steps	매일 걸음 수

- 시계열 데이터 평균, 표준편차, 진단명별 칼럼의 데이터 분포 평균차이 분석
- 치매 분류 모델링을 위한 대상 설정: 55세 이상의 남녀 성인 웨어러블 기기 라이프 로그 데이터
- 치매 분류에 영향을 미치는 특징 분석
 - 걸음 라이프로그 데이터: 하루간 총 사용칼로리, 매일 걸음 수, 하루간 저강도 활동 MET, 비활동 시간, 휴식 시간

2.2 탐색적 데이터 분석

- 상관관계

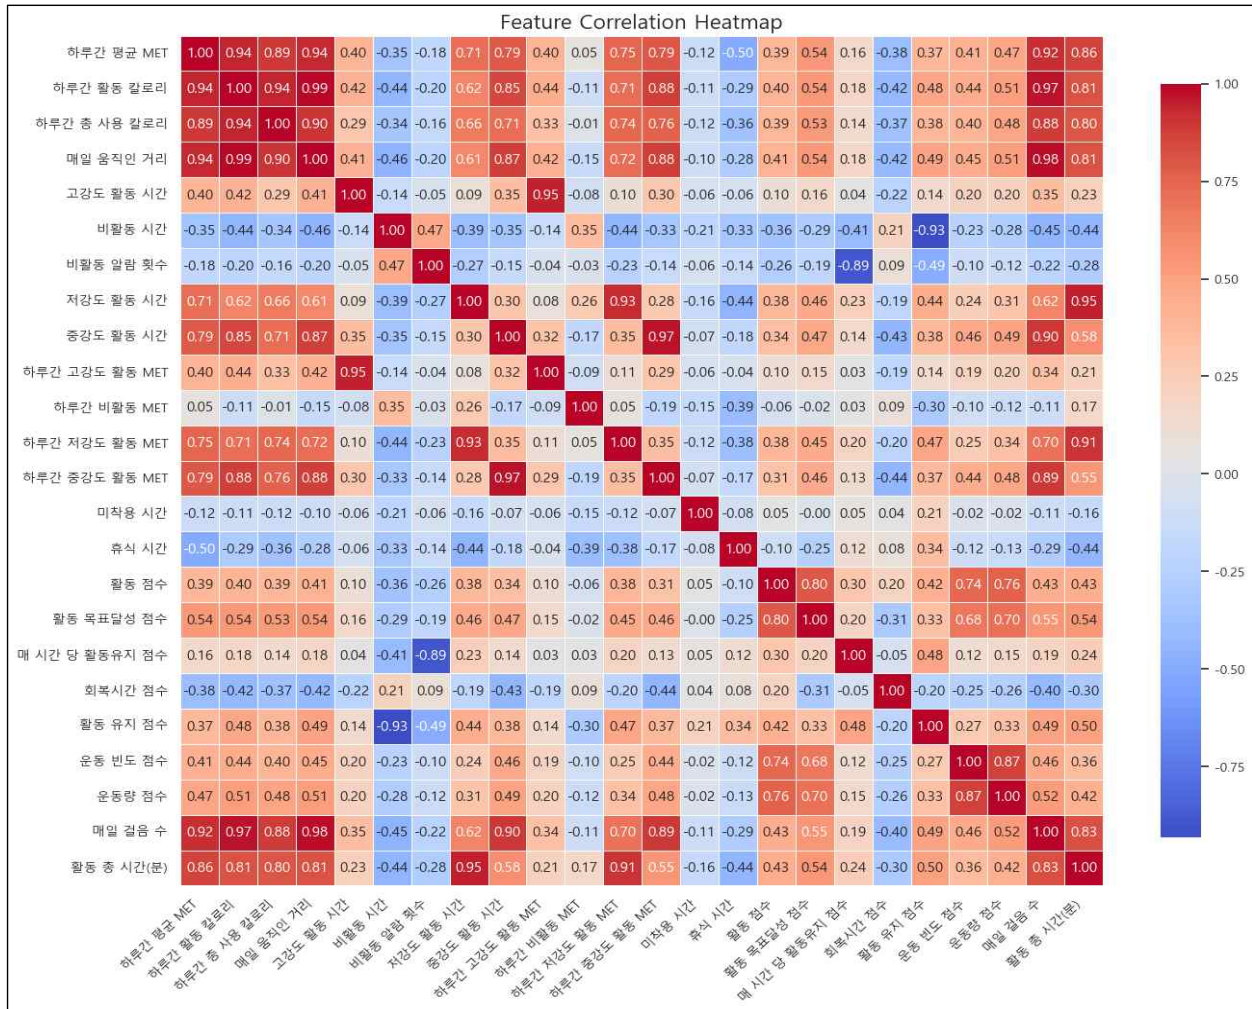


그림 3 상관관계

비고. 칼럼 별 상관관계가 많이 있는 것으로 파악하여, 다중공선성을 우려하여 칼럼을 삭제할 필요성을 확인하였고, Correlation에 의존하지 않고, RandomForestClassifier를 학습하여 어느 칼럼이 중요하게 분류하는데 쓰이는 지 파악해 칼럼을 후진 제거법을 시행하였다.

따라서, 칼럼 10개만 사용해도, 22개의 Numerical 칼럼을 사용했을 때와의 정확도가 같음을 확인할 수 있었다.




그림 4 RandomForestClassifier의 Feature Importances

○ 데이터 전처리

시계열 데이터는 Data Scaler를 적용하기 보다는 그대로 두는 것이 시계열성을 더 잘 반영할 것이라고 생각했다. 그러나, 머신러닝 모델만을 사용해서 분류를 진행할 경우에는, 시계열 데이터의 특성이 무시되어, StandardScaler를 사용하여 정규 분포화 진행하였다.

○ 이상치 분석




그림 5 Z-Score 적용 후 이상치 탐색 BoxPlot

환자의 특성상 더 많이 움직이고, 더 많이 걸으시고, 더 자주 운동하시는 분들이 계시고, 더 적게 움직이는 분들도 계시기 때문에, 데이터 이상치에 대한 처리는 오히려, 데이터의 특성을 무시하는 것이라고 판단했다. 또한 수치형 데이터 칼럼이 22개로 전처리의 어려움이 존재하여 Z-score만 진행하였다.

○ 활동 로그 정규화 (1: 휴식, 2: 저강도, 3: 중간, 4: 고강도)




그림 6 MCI 환자 활동 로그 파이차트




그림 7 CN 환자 활동 로그 파이차트




그림 8 Dem 환자 활동 로그 파이차트

CN: 정상, MCI: 경도 증상, Dem(치매)

치매 환자가 1(휴식) 비활동 시간을 다른 CN, MCI 실험군보다 더 많은 휴식을 가지는 것으로 파악된다. 이는, Dem(치매)라고 판단할 수 있는 좋은 칼럼이 된다.

반대로, CN과 MCI 실험군은 유사하게 데이터가 포진되어 있는 모습을 보아, 분류가 어려울 것으로 판단된다.




그림 9 진단군별 MET 활동 구간 바그래프 (Metabolic Equivalent of Task) : 신진대사당량

위 바그래프를 보시면, Dem 환자가 휴식을 더 많이 취한다는 것을 MET 바그래프로도 알 수 있었다. 이것이 시사하는 바는 위 칼럼이 Dem과 (CN, MCI)를 잘 분류할 수 있는 칼럼이 될 수 있다는 점이다. 그러나 여전히, CN과 MCI를 분류할 수 있는 좋은 피쳐는 아님을 알 수 있다. 그 이유는 비슷하게 데이터가 포진되어 있기 때문이다.

○ 시계열 데이터와 진단명별 평균선 그래프




그림 10 하루간 평균 MET 칼럼에 대한 시계열 그래프




그림 11 하루간 총 사용 칼로리 시계열 그래프

하루간 평균 MET 칼럼의 그래프에서 보이는 평균선인 MCI 실험군의 평균과 CN 실험군의 평균은 유사하게 나타남을 확인할 수 있다. 그러나, 하루간 총 사용 칼로리 시계열 그래프에서 보이는 각 대상군 별 평균선은 모두 다르게 나타남을 알 수 있다. 이는, 머신러닝 모델이 해당 칼럼을 이용하여 분류를 더 잘할 수 있는 기준이 된다. 인간이 분류하기 좋은 칼럼은 머신러닝 모델 또한 분류하기 좋은 칼럼이 된다.

3.1 모델 비교 및 선정

○ 모델 비교

시계열성을 띄고 있는 데이터를 다룰 때는 시계열성을 이해할 수 있는 모델을 선정해야하지만, 머신러닝 모델 중에서는 시계열성을 이해할 수 있는 모델은 고전적 모델 밖에 없다. 더 나아가, 해당 시계열 데이터를 이용하여 분류를 하는 Time Series Classification 모델은 Canonical한 Feature를 뽑아야 하기에 이를 고려해서 고전적인 Time Series Classification 모델 2개와 Tree 기반의 모델과 Gradient 기반의 머신러닝 모델로 학습을 진행하였고, 이 중에서 가장 높은 정확도를 보여주는 모델을 기반하여 최적화(Grid Search)를 진행하여 고도화할 것이다

모델	테스트 정확도
RandomForestClassifier	0.6741
GradientBoostingClassifier	0.6512
AdaBoostClassifier	0.5945
KNeighborsClassifier	0.6394
DecisionTreeClassifier	0.5559
LGBMClassifier	0.5817
CatBoostClassifier	0.6430
XGBClassifier	0.6692
Summary Classifier	0.5383
Catch22 Classifier	0.5801

표 3 Tree 기반의 모델과 Gradient 기반의 모델 그리고 전통적인 시계열 분류 모델(빨간색)

RandomForestClassifier가 가장 높게 나와, RandomForestClassifier로 최적화 (Grid Search)를 진행하였다. 추가로, 정규분포를 가정하고, 평균과 분산을 이용해서 베이지안 모델로 예측을 진행하여 보았지만, 0.47의 정확도를 보여주어 아쉬운 결과를 나타냈다.

○ 최적화 파라미터 및 성능

```
param_grid = {
    'n_estimators': [100, 200, 300],          # 트리 개수
    'max_depth': [None, 5, 10],               # 트리 최대 깊이
    'min_samples_split': [2, 5, 10],          # 내부 노드 분할 최소 샘플 수
    'min_samples_leaf': [1, 2, 4],           # 리프 노드 최소 샘플 수
}
```

최적화 진행 전: 0.6741

최적화 진행 후: 0.6925

1. 데이터 관점

1.84%의 성능 향상을 이끌어 내었지만, 유의미한 성능 향상은 아니었다. 이러한 파라미터 최적화 성능 변화로 알 수 있는 대목은 파생변수를 생성하여 분류를 더 잘할 수 있도록 도모하거나, 새로운 데이터셋을 추가하여 걸음 라이프로그 데이터보다 분류에 유의미한 데이터를 찾아야함을 의미한다.

2. 모델 관점

시계열성을 이해할 수 있는 딥러닝 모델(RNN 계열 또는 Attention계열)을 사용하여 Feature를 재표현해서 학습을 진행하는 Representation Learning 계열의 모델이 필요하다.




그림 12 Attention 계열 딥러닝 모델 (BERT)

4. 프로토타입

4.1 데이터 시각화

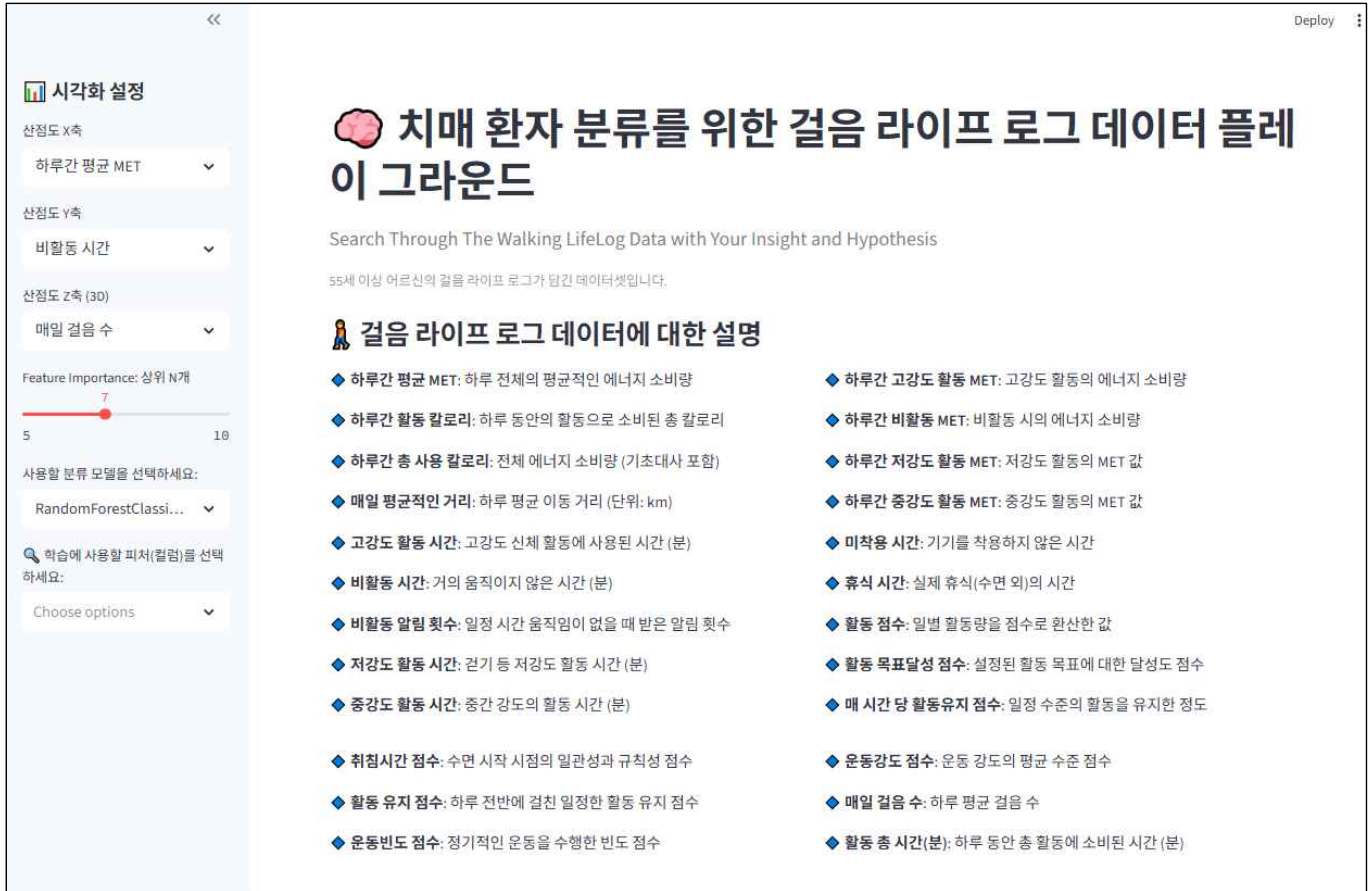


그림 13 메인 페이지 (걸음 라이프 로그에 대한 설명)

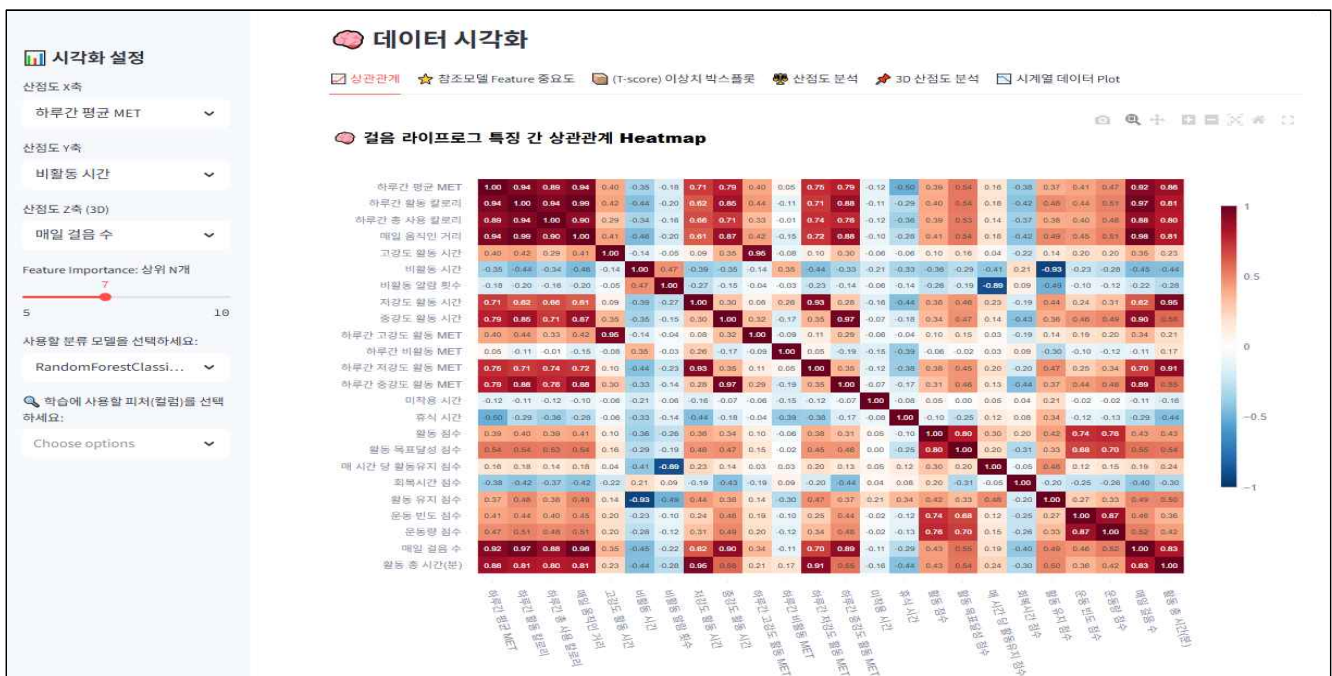


그림 14 데이터 시각화 화면 (상관관계)



그림 15 데이터 시각화 화면 (피쳐 임포rts)




그림 16 분류 모델과 성능 평가