2025년도 공공기관 용역과제

AI개발 수행내역서

과제명	ML기반 허리 통증 예측모델 개발 및 시각화
담당자	강충원

2025년 7 월 29 일

AI개발 수행내용

사업과제 : IPUMS 데이터를 활용한 허리 통증 예측 ML모델 개발

1. 개요 및 현황

1.1 추진배경 및 목적

○ 근무 환경 및 생활습관 변화로 근골격계 질환, 특히 허리 통증의 발생률이 증가하고 있음
○ 건강조사 및 생체 데이터를 활용한 통증 예측 AI 모델 수요가 확대되는 추세임
○ 의료자원 한계 속에서 허리 통증 고위험군 조기 식별 및 예방 관리의 필요성이 증가함
○ 직업, 운동, 건강 인식 등 주요 요인을 기반으로 허리 통증 예측 머신러닝 모델을 개발함
○ 허리 통증을 시작으로 추후 어깨·무릎 등 통증 예측 모델로 확장 가능한 기반 마련이 목표임

1.2 과제 범위

과제구분		내용
AI	AI기반 허리통증 예측 모델 개발	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		Accuracy, F1 Score 등 평가지표를 활용한 모델 성능 평가
		Streamlit기반 웹 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	건강 정보 입력 및 통증 예측 시각화	예측 모델 간의 ROC커브 시각화 구현
		건강 정보 입력 구현
		예측결과 시각화
		테스트

1.3 과제 추진 방법

1.3.1 구축 대상 선정 기준

○ 데이터 접근성 및 활용성
- ■ 공공기관(국민건강보험공단, 질병관리청 등)에서 수집한 건강조사 데이터를 활용할 수 있음
- ■ 연령, 직업, 운동 빈도, 신체정보, 통증 여부 등 핵심 변수들이 정형화되어 있어 처리 및 분석이 용이함
- ■ 다양한 건강 관련 변수들이 포함되어 있어 통증 발생 예측에 유의미한 기여 가능

○ 예측모델 개발 효율성
- ■ 통증 유무 및 등급이 명시된 범주형 종속변수를 기반으로 비교적 단순한 구조의 모델 설계 가능
- ■ 구축된 모델은 어깨·무릎 등 다른 근골격계 통증 예측으로도 확장 적용 가능

○ 건강관리 기여도 및 경제성

- ■ 고위험군 사전 예측을 통해 개인 맞춤형 예방 및 개입이 가능하여 의료자원 효율성 제고
- ■ 근골격계 질환으로 인한 진료비, 노동손실 등 사회·경제적 부담 경감에 기여
- ■ 예측모델 기반의 조기 예방 서비스는 공공보건 및 산업안전 관리체계에 효과적으로 적용 가능

1.3.2 AI 예측 분석모델 적용 대상

구분	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
허리 통증 정도	- IPUMS 2023 건강 정보 데이터 - 통증 정도가 포함된 데이터셋	- 직업변수: OCCUPN204, INDSRN204, HOURSWRK - 인종변수: RACENEW - 설문변수: HEALTH - 신체변수: HEIGHT, WEIGHT, BMICALC, BMICAT - 통증변수: PAINARMS3M, PAINLEGS3M	- 본인의 정보들을 바탕으로 종합적으로 분석하여 허리 통증 유무 예측

1.3.3 AI 분석모델 구축 프로세스

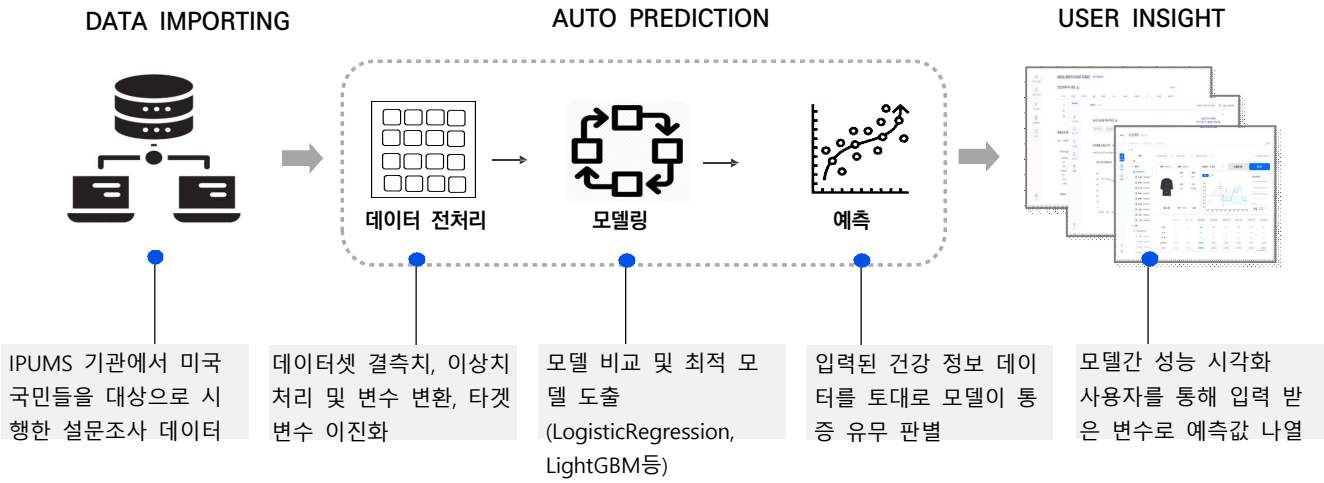

연구개발 주요 결과물

1. 데이터 수집 및 개요

1.1 데이터 출처

IPUMS Health Surveys: NHIS (National Health Interview Survey), 2023년도 표본 데이터
출처 : https://healthsurveys.ipums.org/

1.2 데이터 구성 및 변수 구성

전체 데이터셋은 총 37,214개의 행과 14개의 열로 구성되어 있으며, 다음과 같은 의미를 보임

- OCC: 직업코드
- IND: 산업코드
- RACENEW: 인종
- OCCUPN204: 직업군
- INDSRN204: 산업군
- HOURSWRK: 주당근로시간 1~95
- HEALTH: 자가건강인식 1(좋음)~ 5(나쁨)
- HEIGHT: 신장 12~ 95
- WEIGHT: 체중 100~299
- BMICALC: BMI
- BMICAT: BMI 구간
- PAINBACK3M: 허리통증정도 1(무통증)~4(중간 통증)
- PAINARMS3M: 어깨통증정도 1(무통증)~4(중간 통증)
- PAINLEGS3M: 다리통증정도 1(무통증)~4(중간 통증)

데이터는 **0(NIU)**과 **(7, 8, 9, 996 등)결측치코드**가 포함되어 있음

2. EDA

2.1 탐색적 데이터 분석

2.1.1 결측치 확인

모든 변수에는 결측치 코드에 해당되는 값이 관측
결측치 비율은 0.03% ~ 41.96% 범위로 분포
가장 높은 결측치 비율: OCCUPN204 직업군 (41.96%)

```
OCCUPN204     41.96
INDSTRN204    41.89
BMICALC        8.84
WEIGHT         8.70
HEIGHT         7.29
race_group     4.18
RACENEW        4.18
BMICAT         1.88
HEALTH         0.05
PAINLEGS3M     0.03
PAINARMS3M     0.03
HOURSWRK       0.00
IND            0.00
OCC            0.00
PAINBACK3M     0.00
dtype: float64
```

3. 데이터 전처리

3.1. 결측치 처리

활용할 수 없는 데이터는 드랍 제거, 결측치 비율이 적은 데이터는 중앙값, 평균값 대체

- 타겟 변수인 PAINBACK3M의 결측치는 활용할 수 없기 때문에 해당되는 데이터 드랍
- ~~OCCUPN204, INDSTRN204 결측치 OCC, IND 칼럼에서 대응되는 정수로 대체(상관관계 관측)~~

=> OCCUPN204, INDSTRN204 결측치 드랍

- BMICALC 결측치 중앙값으로 대체
- WEIGHT, HEIGHT 결측치 평균으로 대체
- BMICAT BMI카테고리 제거
- HEALTH 결측치 최빈값 대체

3.2 이상치 처리

- BMICALC 50 이상인 이상치 제거

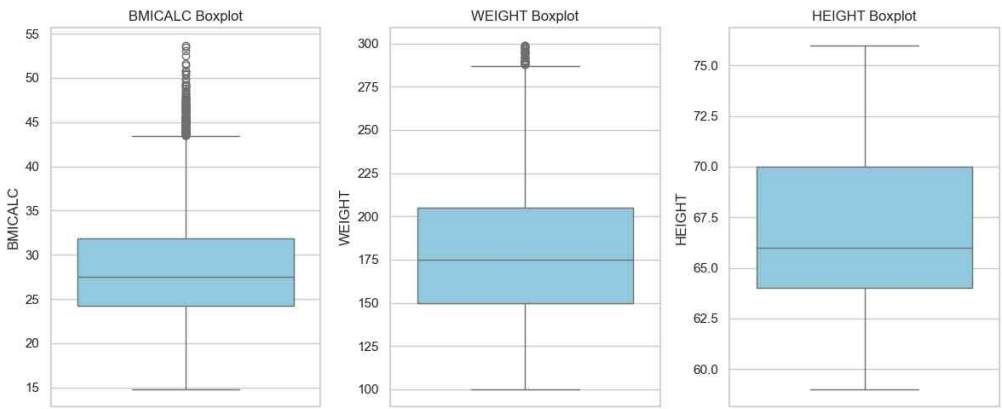

BMI 50 초과는 **CDC(미국 질병통제예방센터)** **병적 비만군으로 간주**되며 예측 모델에서 해당 집단의 분포가 지나치게 왜곡될 우려가 있어, 임계값 50을 기준으로 이상치를 제한적으로 제거하였다.

- 자료 링크: https://en.wikipedia.org/wiki/Obesity

3.3 변수 변환/정리

- RACENEW 인종 변수 그룹화 → race_group
- OCCUPN204, INDSTRN204 각각 그룹 3개로 그룹화 → Occ_Group, Ind_Group

```
sedentary_jobs = [1, 2, 3, 4, 5, 7, 8, 10, 16, 17]  # 사무직 계열
active_jobs = [12, 13, 14, 15, 18, 19, 20, 21, 22, 23]  # 신체 활동 많은 직업
mixed_jobs = [6, 9, 11]  # 활동 다양성 있음

def categorize_occupation(code):
    if code in sedentary_jobs:
        return 'Sedentary'
    elif code in active_jobs:
        return 'Active'
    elif code in mixed_jobs:
        return 'Mixed'
    elif code in [97, 98, 99, 0]:
        return 'Unknown'
    else:
        return 'Other'

df['Occ_Group'] = df['OCCUPN204'].apply(categorize_occupation)
```

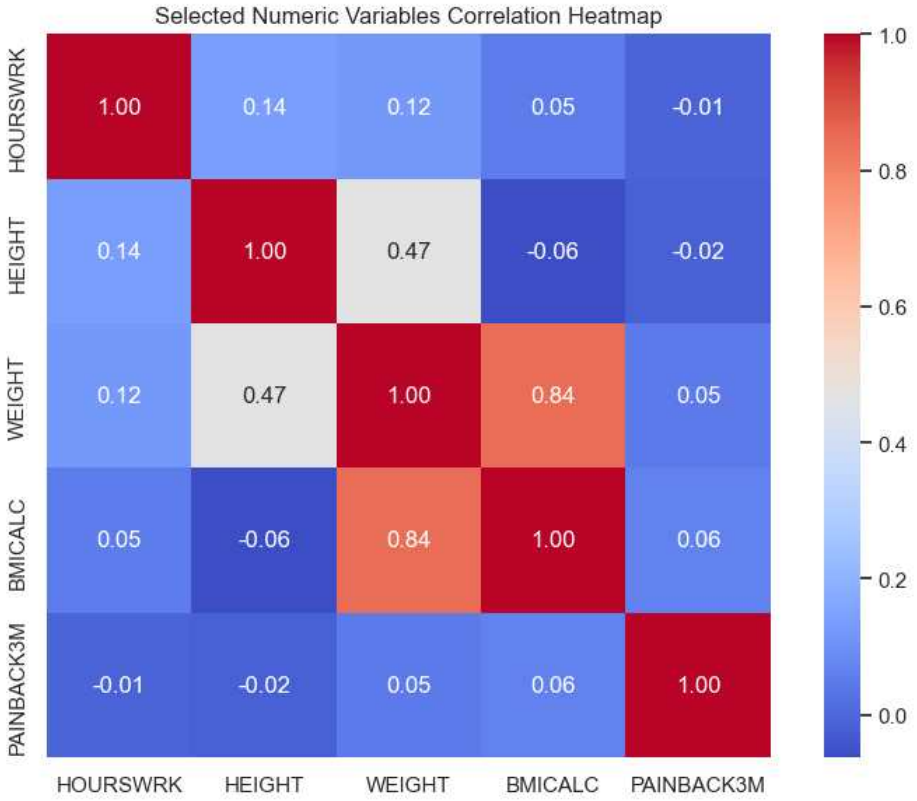

변수 간 상관계수 히트맵을 봤을 때 WEIGHT 변수와 BMICALC 변수가 0.84로 높은 양의 상관관계를 보임

다중 공선성 문제가 있는지 확인해보고자 함

WEIGHT 변수 제외 경우, BMI 변수 제외 경우, 두 변수 포함 경우 비교

두 변수 포함의 경우가 성능이 제일 높게 나옴

→ **두 변수 포함 채택**

3.4 범주형 변수 인코딩

6개와 3개의 그룹을 가지는, 범주 간 순서가 존재하지 않는 명목형 변수(nominal)이므로, 각 범주를 독립적인 특성으로 처리할 수 있는 원-핫 인코딩(One-Hot Encoding) 방식이 적합하다 판단하여 적용

- race_group, Occ_Group, Ind_Group 원-핫 인코딩

```
# 전처리 파이프라인 구성
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numerical_cols),
        ('cat', OneHotEncoder(drop='first', handle_unknown='ignore'), categorical_cols)
    ]
)
```

3.5 수치형 변수 스케일링

HOURSWRK, HEIGHT, WEIGHT, BMICALC 분포 시각화

- **StandardScaler 수행**

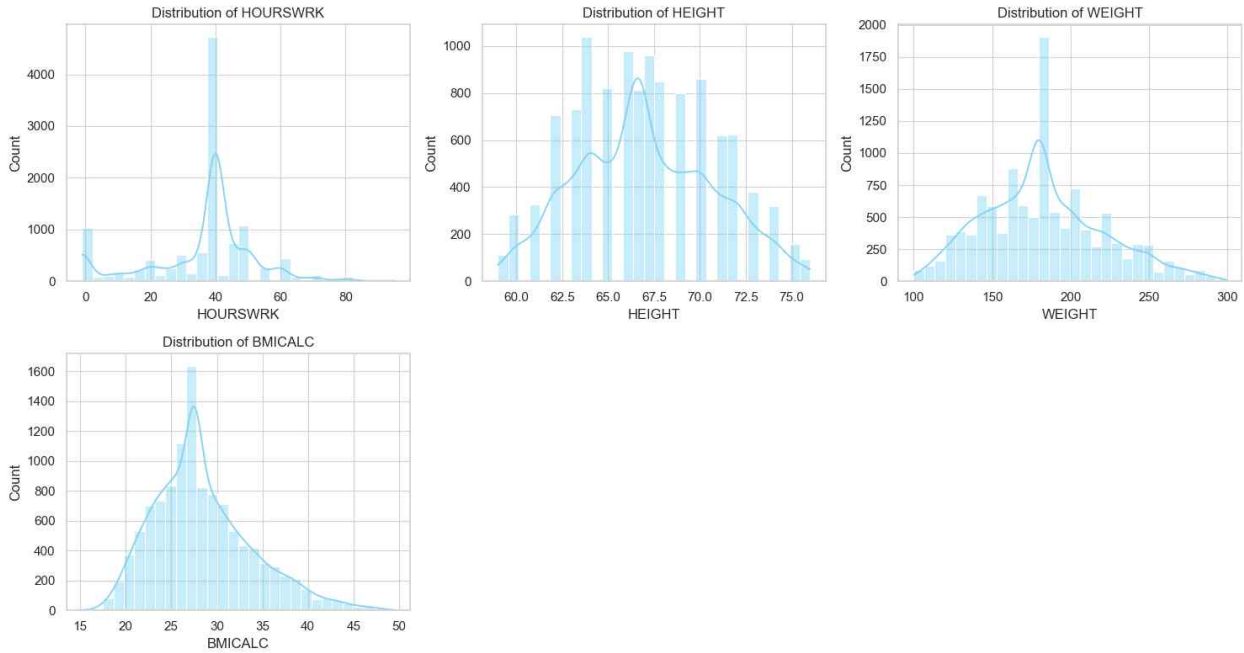

수치형 변수들(근로시간, 키, 몸무게, BMI)은 서로 다른 단위와 스케일을 가지며, 일부 변수(WEIGHT, BMICALC)는 왜도가 큰 분포를 보이므로, 모델 학습의 안정성과 성능 향상을 위해 StandardScaler를 적용하여 평균 0, 표준편차 1로 정규화하였다.

3.6 종속 변수 이진화

타겟 변수 PAINBACK3M은 1(무통증), 2(약간 통증), 3(매우 통증), 4(2와3 사이 통증)의 의미이므로 1은 0(무통증) 2, 3, 4는 1(통증)을 의미하는 이진 변수로 변환

- PAINBACK3M : 1, 2, 3, 4 → **0, 1**

```
X = df_cleaned[num_cols + cat_cols]
y = df_cleaned['PAINBACK3M'].apply(lambda x: 0 if x == 1 else 1)
```

4. 모델 선정 및 성능 평가

4.1 모델 비교

LogisticRegression, LightGBM, XGBoost, RF모델 중 LogisticRegression모델 최고 성능

- (Accuracy: 0.6787271142109852)

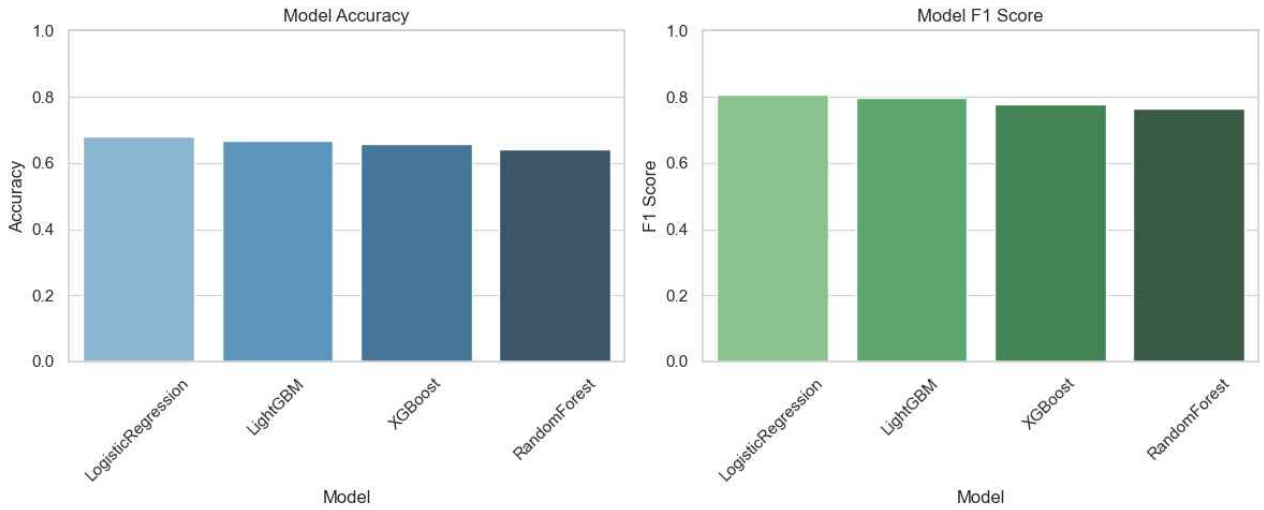

4.2 피쳐중요도

차지하는 비율 적지만 피쳐중요도 값이 큰 변수 발견

- race_group의 Other/Multiple 그룹
- 실제 비율은 1.5%로 작지만 모델에 주는 영향이 상대적으로 큼

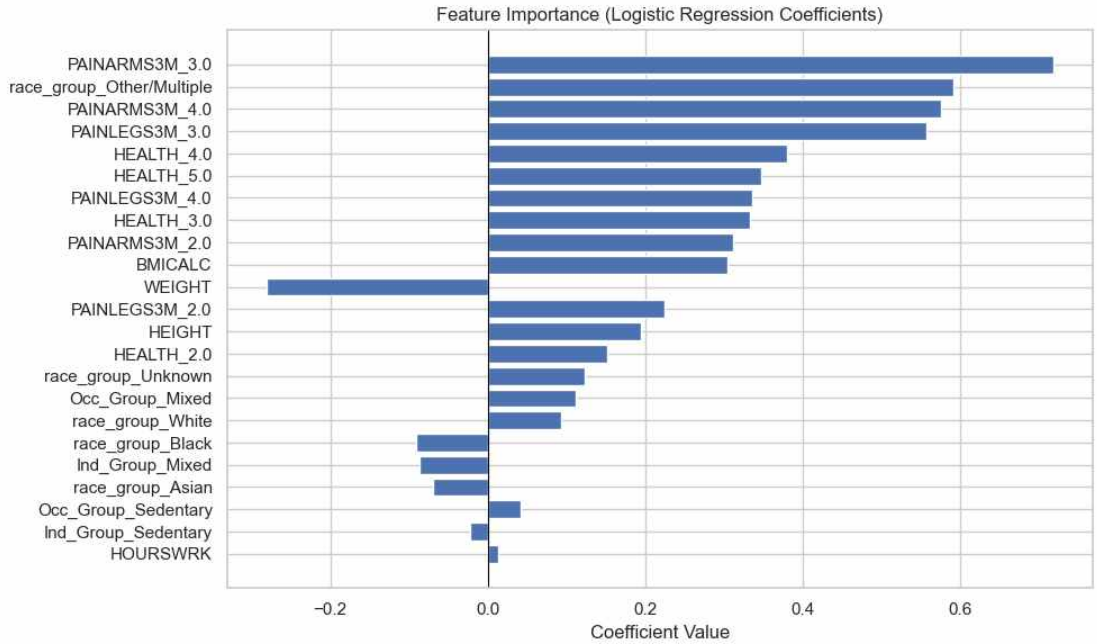

→ 모델의 해당 독립 변수를 제거할지 그룹 통합 및 L1 규제를 할지 검토해야함

4.3 모델 독립 변수(입력 변수) 변경

4.3.1. 인종 변수 희귀 그룹 통합 vs 인종 변수 삭제

- (1안) 인종 변수 희귀 그룹 통합 및 L1 규제
- (2안) 인종 변수 삭제

1안과 2안 모델 성능 비교

- 1안: Accuracy: 0.5832606800348736
- 2안: Accuracy: 0.5806451612903226

큰 차이 없음

4.3.2. 인종 변수 포함 vs 인종 변수 미포함

```
A_including_race   | Acc 0.571±0.010 | F1 0.585±0.009
B_no_race          | Acc 0.570±0.010 | F1 0.584±0.010
```

→ 차이가 없기 때문에 **변수 삭제**로 모델 해석력, 공정성 측면에서 강화

4.4. confusion matrix

로지스틱 회귀 모델의 confusion matrix 시각화

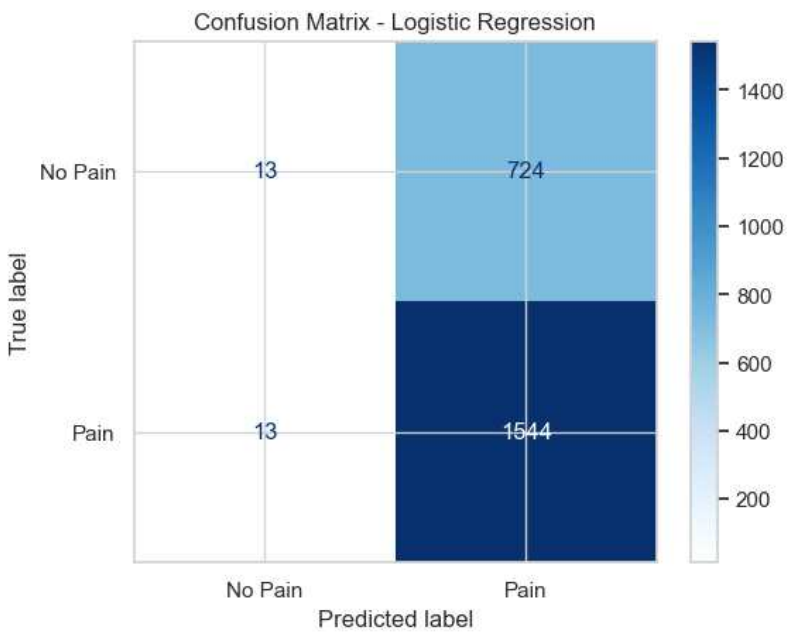

혼동 행렬 결과, 실제 통증이 없는 대상자 중 724명이 통증이 있는 것으로 잘못 분류되어 모델의 과탐지(False Positive)가 두드러짐.

이는 모델이 통증 여부 예측 시 민감도(99%)는 높지만, 특이도(1.77%)가 낮아 과잉 진단 가능성이 존재함을 시사함.

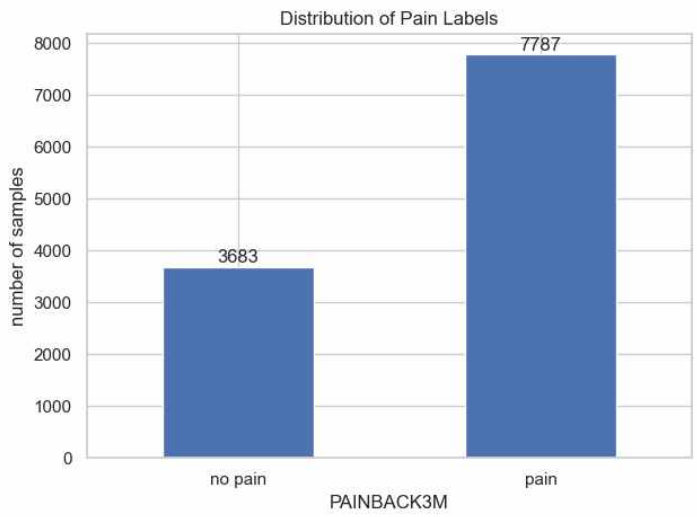

- 원인: 타겟 변수의 **클래스 불균형이 문제**(무통증:3683, 통증:7787)
- 해결방안: 클래스 불균형을 해결하기 위해 SMOTE 공법 사용하여 적은 클래스를 오버샘플링 시도

(SMOTE 오버샘플링 이후 모델 비교)

Model	Accuracy	F1	ROC_AUC	Precision	Recall
LogReg	0.574	0.640	0.611	0.750	0.558
RF	0.621	0.738	0.565	0.696	0.786
LGBM	0.638	0.760	0.574	0.691	0.843
XGB	0.638	0.757	0.580	0.695	0.833

성능지표를 비교해보니 LGBM 모델이 가장 합리적
+ 추가 설명: 의료 도메인 관점에서 보았을 때 **Recall 지표가 제일 중요**하기 때문에 **LGBM 채택**

5. 모델 최적화 및 학습 결과
최종 모델 : LightGBM

5.1 하이퍼 파라미터 튜닝
Optuna 라이브러리 활용
이 OptunaSearchCV는 GridSearch처럼 모든 조합을 탐색하지 않고,
총 50번의 실험(n_trials=50) 안에서 이전 결과를 반영한 탐색적 최적화를 수행합니다.

최적 파라미터 :
- model__subsample: 0.9675
  의미: 각 트리를 학습할 때 사용하는 데이터 샘플 비율
- model__colsample_bytree: 0.6557
  의미: 각 트리를 만들 때 사용할 특성(feature)의 비율
- model__reg_lambda: 0.4454
  의미: L2 정규화 항(가중치 제곱합 패널티)의 강도
- model__reg_alpha: 0.0303
  의미: L1 정규화 항(가중치 절댓값 패널티)의 강도

5.2 이전 모델과 최종 모델 ROC커브 시각화

LogisticRegression vs LightGBM(SMOTE + Optuna)

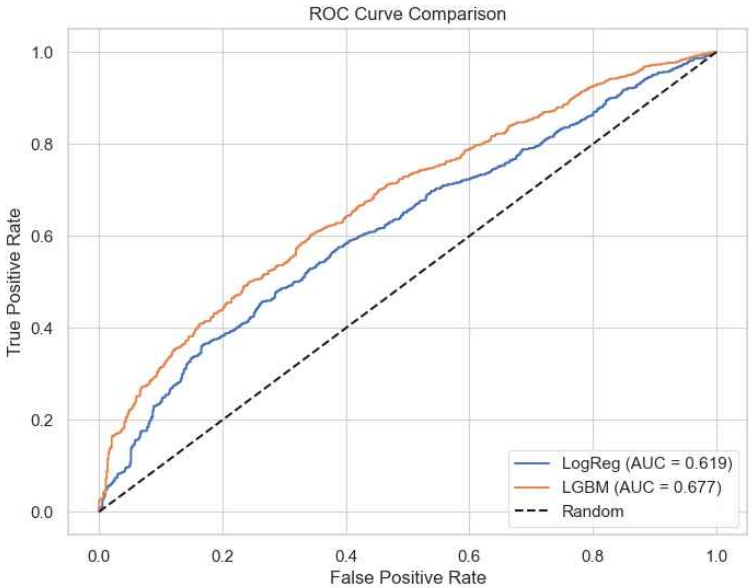

ROC 곡선 비교 결과, LGBM 모델의 AUC는 0.677로 로지스틱 회귀 모델의 0.619보다 높아, 통증 여부 예측에서 더 우수한 분류 성능을 보임

5.3. 의료 도메인 관점에서의 성능 해석

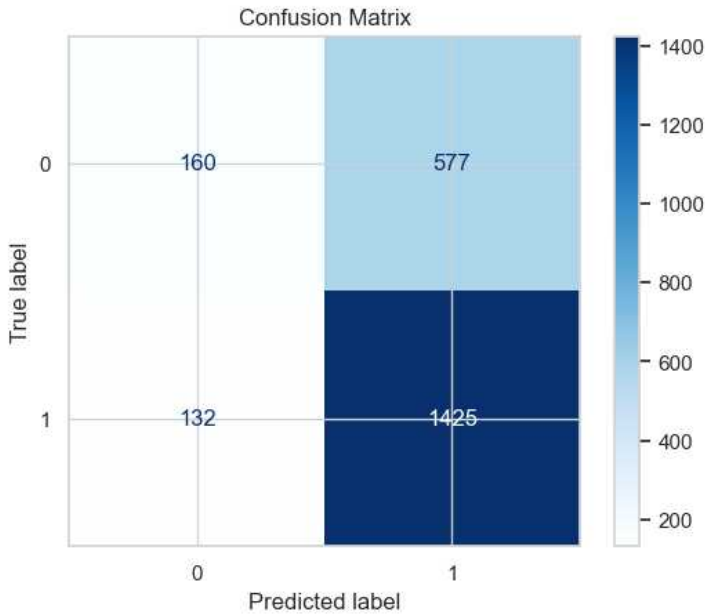

이 LGBM 모델은 통증 여부를 예측하는 데 민감도는 매우 높지만, 특이도는 낮아 실제 진단보다는 선별(Screener)용 보조도구로 적합

의료 도메인에서는 오진 위험을 최소화하거나 threshold 조정 및 후속검사와 연계해 활용하는 것이 바람직함

6. Streamlit 상호작용 시각화

6.1. 모델 비교 시각화 페이지

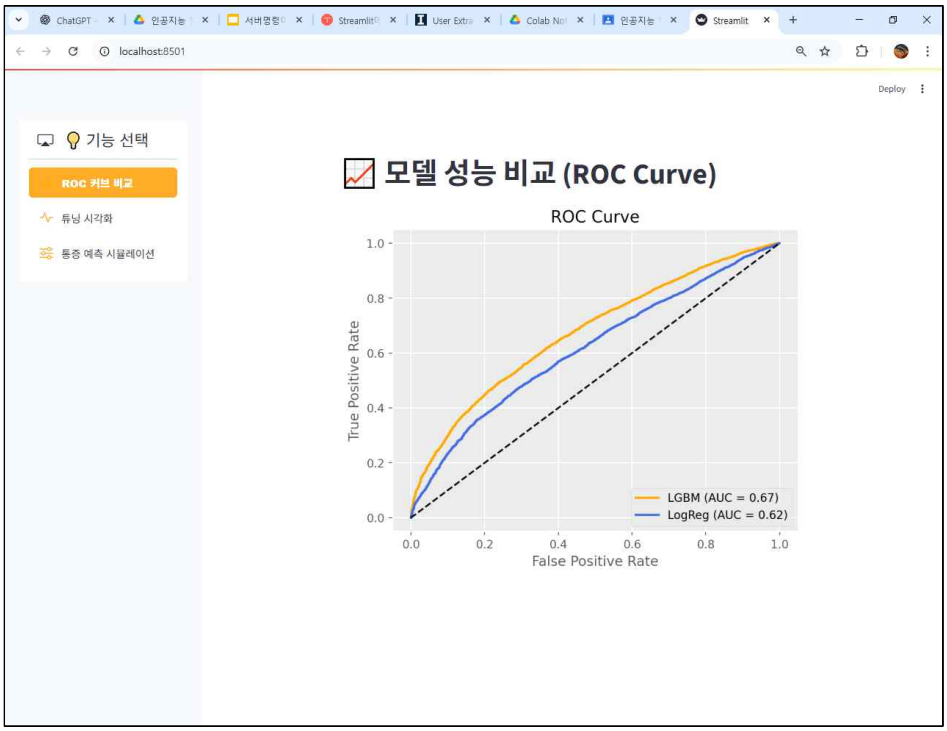

ROC 커브는 각 모델의 분류 성능을 시각적으로 비교할 수 있는 지표로, 곡선 아래 면적(AUC)이 클수록 더 뛰어난 예측력을 의미합니다.

6.2. 하이퍼 파라미터 튜닝 시각화

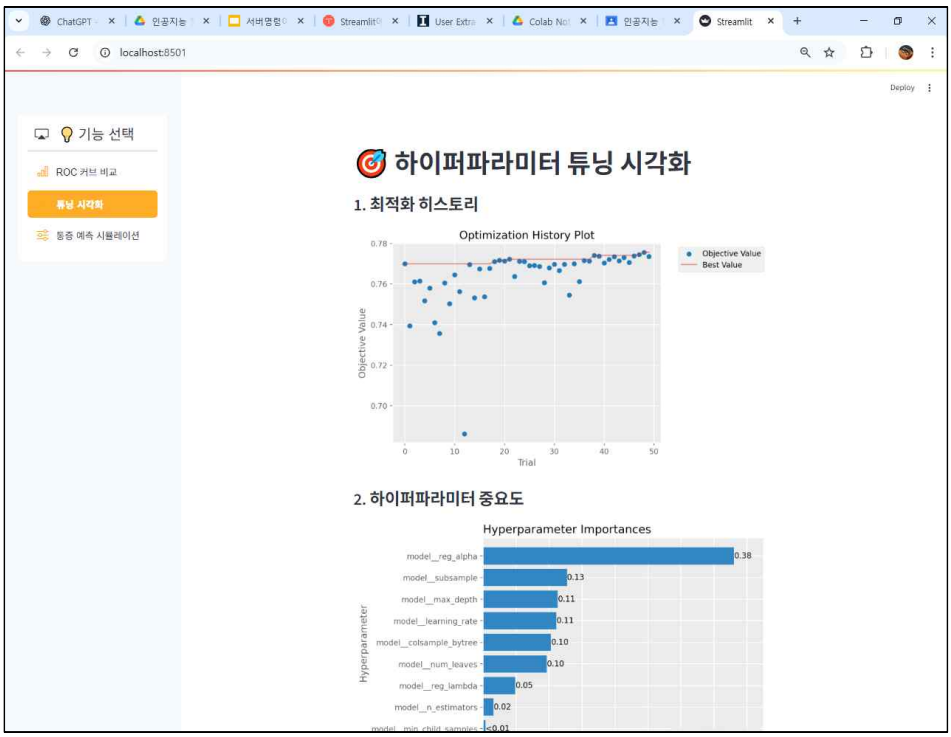

Optuna를 이용한 하이퍼파라미터 튜닝 과정을 시각화하여 모델 성능에 영향을 준 요소와 탐색 과정을 분석할 수 있습니다.

6.3. 변수 입력 예측 페이지

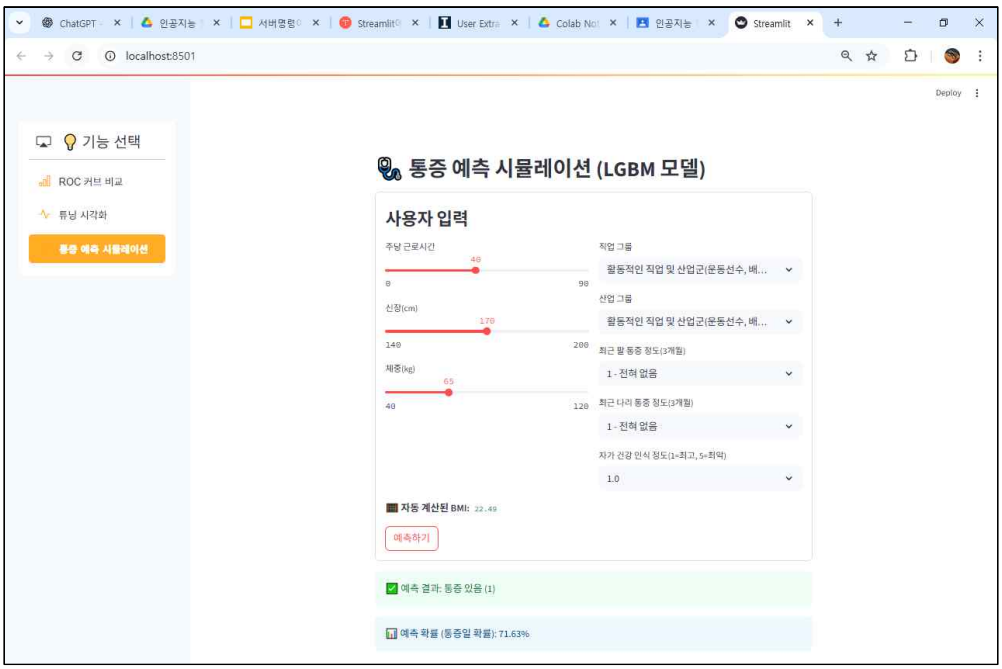

사용자가 입력한 건강정보와 직업·산업 특성, 기존 통증 경험 등을 바탕으로 머신러닝 모델이 향후 통증 발생 가능성을 예측합니다.

7. 결론 및 향후 계획

7.1 모델 개발 결과 요약

본 프로젝트에서는 LightGBM 기반 이진 분류 모델을 개발하여 통증 여부를 예측하였으며, AUC는 0.67, 통증 환자에 대한 민감도는 약 91.5%로 나타남.

특히, 통증 환자를 놓치지 않는 높은 민감도 측면에서 스크리닝 목적에 적합한 성능을 보임.

7.2 실무 적용 방안

모델은 간단한 설문 기반 정보(직업군, 통증 이력, 건강 인식 등)만으로도 높은 통증 탐지 성능을 보이므로, 병원 접수 전 간이 문진 시스템이나 근골격계 건강 리스크 예측 시스템의 초기 필터로 활용할 수 있음.

또한 통증 이력과 생활 패턴을 반영한 상담 또는 검진 우선순위 결정에 유용할 수 있음

7.3 한계점 및 개선 방향

현재 모델은 무통증 대상자를 통증으로 과잉 예측하는 경향이 있으며, 특이도가 낮아 정밀 진단에는 한계가 있음.

향후에는 클래스 불균형 보정, 예측 임계값 조정, 의료 전문가 피드백 기반 feature 보강을 통해 정밀도와 특이도를 함께 개선할 계획이다.