

2025년도 공공기관 용역과제
AI개발 수행내역서

과제명	NGS 기반 항암 약물 반응 예측 AI 모델 개발
담당자	장소영

2025년 12 월 29 일

AI개발 수행내용

1. 사업과제 : NGS 기반 항암 약물 반응 예측 AI 모델 개발


2. 개요 및 현황

2.1 추진배경 및 목적

- 암은 국내 주요 사망 원인 중 하나로, 고령화 사회 진입에 따라 발생률과 사망률이 지속적으로 증가하는 추세임. 특히 폐암, 대장암 등 고형암은 치료 예후가 불량하며, 기존 항암제에 대한 내성 문제로 새로운 치료 전략 개발의 필요성이 증가하고 있음¹⁾.
- 암 발생 기전 중 KRAS 돌연변이는 폐암 및 대장암 등에서 높은 빈도로 관찰되며, **MAPK 신호 전달 경로(RAF-MEK-ERK)**를 활성화하여 암세포 증식과 생존을 촉진하는 주요 요인임. 해당 경로는 암 치료의 핵심 표적으로 주목받고 있으나, KRAS 변이 특성상 기존 표적 치료제 개발에는 한계가 존재함²⁾.
- 선행연구로 수행한 세포 기반 실험에서는 항암 후보 물질 처리군과 대조군 간 비교를 통해 MAPK 신호전달 경로(RAF-MEK-ERK)의 변화 양상을 Western blot으로 확인하였으며, 약물 처리에 따라 해당 경로 단백질 발현이 감소하는 경향을 확인하였음. 이는 약물 반응이 특정 세포 신호 경로 수준에서 차이를 보일 수 있음을 시사함³⁾.
- 다만 기존 실험은 제한된 단백질 및 조건 중심의 분석으로, 대규모 유전자 발현 수준에서의 약물 반응 기작을 포괄적으로 해석하는 데에는 한계가 있음. 이에 따라 RNA-seq 기반 유전자 발현 데이터를 활용하여 약물 반응을 예측하고, 관련 기작을 체계적으로 분석할 수 있는 AI 모델 개발의 필요성이 대두됨³⁾.
- 본 과제에서는 기존 선행연구에서 제시된 실험적 결과와 기전 가설을 기반으로, RNA-seq 유전자 발현 데이터를 활용한 AI 기반 분석 모델을 구축하여 약물 반응을 예측하고 분자 수준의 해석을 보완하고자 한다.



[그림 1] 인간 사망 원인 및 사망률




[그림 2] MAPK pathway

2.2 과제 범위

과제구분	내용
데이터 수집	RNA-seq 기반 유전자 발현 데이터(Expression count) 확보 및 처리군/대조군 샘플 구성
데이터 전처리	로그 변환(log2), 저발현 유전자 필터링, 유전자 샘플 기준 정규화 수행
모델링	Logistic Regression(L2) 기반 feature selection 수행
예측 모델	Random Forest와 Logistic Regression을 결합한 Soft Voting 모델 구축
성능 평가	LOOCV 기반 Accuracy, ROC-AUC, Confusion Matrix 평가 수행
중요도 및 기작 분석	모델에서 선택된 핵심 유전자 Top-N 도출 및 gProfiler 기반 GO/KEGG enrichment 분석 수행
시각화	모델 성능 지표 및 pathway enrichment 결과 시각화
한계 및 개선방안	

수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
RNA-seq gene expression	- log2 변환된 유전자 발현량 - Feature selection으로 선택된 핵심 유전자	- 약물 반응에 따른 처리군/대조군 분류 결과
유전자 심볼 기반 feature	- 예측 확률(proba) 및 분류 결과	- 약물 반응 관련 경로 분석

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1) 통계청, 「사망원인 추이」

1. 데이터 수집

- 본 과제에서는 **RNA-seq 기반 유전자 발현 데이터(Expression count)**를 AI 분석의 입력 데이터로 활용하였다.
- 약물 처리군(12b)과 대조군(Control)으로 구성된 세포 샘플의 RNA-seq 데이터를 수집하였으며, 각 샘플은 유전자별 read count 형태의 발현량 정보를 포함한다.
- 수집된 데이터는 이후 전처리 및 모델 학습을 위해 샘플 × 유전자 행렬 구조로 정리하여 분석에 사용하였다.


Gene_ID	Transcript_ID	Gene_Symbol	Description	gene_biotype	Protein_ID	HGNC	MM	Ensembl	MGI/GENE	D8h-12b1_Read	8h-12b2_Read	8h-12b3_Read	48h-C1_Read	48h-C2_Read	48h-C3_Read	8-48h-12b1_F8	8-48h-12b2_F8	8-48h-12b3_F8	48h-48h-C1_F4	48h-48h-C2_F4
1	NM_130786	AT6G	alpha-1-B glyx protein_coding	NP_070802.2	5	138670				60	85	59	31	57	45	0.242583	0.403644	0.298292	0.148357	0.260332
2	NM_000014	NI A2M	alpha-2-macroglobulin	NP_000005.3	7	103950				0	0	0	0	0	0	0	0	0	0	0
3	NR_040112	A2MP1	alpha-2-macroglobulin	NP_000005.3	8					0	0	0	0	0	0	0	0	0	0	0
9	NM_000662	NI NAT1	N-acetyltransferase	NP_000653.3	7645	108345				110	65	93	101	114	85	0.729579	0.502609	0.743738	0.772385	0.819895
10	NM_000015	NI NAT2	N-acetyltransferase	NP_000006.2	7646	612182				0	0	4	2	0	0	0	0	0.040918	0.019482	0
12	NM_001085	SERPINA3	serpin family A member 3	NP_001076.2	16	107280				4	0	0	4	0	0	0.033856		0	0.034973	0
13	NM_001086	NI AADAC	arylsulfatase	NP_001077.2	17	600338				0	0	0	0	0	0	0	0	0	0	0
14	NM_001087	NI AAMP	angiotensinogen	NP_001078.2	18	603488				6354	5674	5207	5992	6091	5698	49.45278	52.004931	49.992809	55.725002	53.221753
15	NM_001088	NI AANAT	aralkylamine N-acetyltransferase	NP_001079.1	19	600950				0	4	0	2	4	0	0	0.011013	0	0.005369	0.012342
16	NM_001025	NI AARS1	alanine aminotransferase	NP_001096.2	20	601065				28797	24349	22693	24552	25085	21893	115.607329	115.212022	113.182107	117.566873	113.369247
18	NM_000662	NI ASAT	4-aminobutyrate aminotransferase	NP_000654.2	23	137150				958	760	686	732	842	694	2.757621	2.488907	2.452464	2.521441	2.725043
19	NM_005502	NI ABCA1	ATP binding cassette protein	NP_005493.2	29	600046				0	0	0	0	0	0	0	0	0	0	0
20	NM_001606	NI ABCA2	ATP binding cassette protein	NP_001597.2	32	600047				22423	21550	21097	17956	20292	19142	38.244911	43.357835	44.699539	36.606247	38.899426
21	NM_001089	ABCA3	ATP binding cassette protein	NP_001080.2	33	601615				9096	8546	8231	8066	8791	7757	18.988346	21.030649	21.347765	20.120508	20.635656
22	NM_00127169	ABCB7	ATP binding cassette protein	NP_001258625	48	300135				3370	2592	2678	2331	2521	2090	10.107813	9.179892	9.98247	8.35555	8.506126
23	NM_00102509	ABCF1	ATP binding cassette protein	NP_001020262	70	603429				4414	3706	3501	3852	4201	3553	17.878188	17.696533	17.628263	18.64406	19.116049
24	NM_000350	ABCA4	ATP binding cassette protein	NP_000341.2	34	601691				73	57	56	42	47	45	0.136751	0.126117	0.128549	0.092549	0.098853
25	NM_005157	NI ABL1	ABL proto-oncogene	NP_005148.2	76	189980				6246	5271	5103	4773	4949	4431	15.041458	14.961383	15.320337	13.744184	13.437402
26	NM_001091	NI ADC1	amine oxidase	NP_001082.2	80	104610				4	21	15	30	12	17	0.018902	0.121255	0.09226	0.179142	0.067696
27	NM_00113600	ABL2	ABL proto-oncogene	NP_001129472	77	164690				5104	4186	4042	4286	4472	3618	6.084562	5.723987	5.893294	5.947568	5.86596
28	NM_020469	ABO	ABO, alpha 1 - protein	NP_065202.2	79	110300				1674	1534	1491	1648	1920	1702	3.638895	3.930305	4.025502	4.279564	4.692333
29	NM_001092	NI ABR	ABR activator	NP_001083.2	81	600365				9039	8126	7694	7037	7877	6748	22.004387	23.116481	23.440386	20.471551	21.550403
30	NM_00113041	ACAA1	acetyl-CoA acyltransferase	NP_001123882	82	604054				2300	1959	1835	2461	2582	2294	18.412162	18.435127	18.386305	23.67821	23.404649
31	NM_198834	NI ACACA	acetyl-CoA acyltransferase	NP_942131.1	84	200350				8429	7489	7087	7993	9101	7806	11.817871	12.278646	12.500782	13.440397	14.380532
32	NM_001093	NI ACACB	acetyl-CoA acyltransferase	NP_001084.3	85	601557				2159	1795	1848	1509	1672	1524	3.236798	3.111139	3.408142	2.650151	2.753094
33	NM_001608	NI ACADL	acyl-CoA dehydrogenase	NP_001599.1	88	609576				0	0	0	0	0	0	0	0	0	0	0
34	NM_000016	NI ACADM	acyl-CoA dehydrogenase	NP_000007.1	89	607008				1100	940	788	1110	1152	807	6.544634	6.606415	5.727415	7.825165	7.664359
35	NM_000017	NI ACADS	acyl-CoA dehydrogenase	NP_000008.1	90	606985				2319	2338	1995	1911	1976	1622	17.181518	20.424941	18.277754	16.927428	16.459912
36	NM_00133017	ACADSB	acyl-CoA dehydrogenase	NP_001317103	91	606301				2374	1788	1641	1735	1956	1561	5.609372	4.979999	4.811384	4.884709	5.183212
37	NM_000018	NI ACADVL	acyl-CoA dehydrogenase	NP_000009.1	92	609575				25528	20740	20698	23642	25808	23153	160.964977	153.117245	160.96003	176.351124	182.543953
38	NM_000019	NI ACAT1	acetyl-CoA acyltransferase	NP_000010.1	93	607809				6153	5095	4553	6155	6488	5433	52.843052	52.572725	48.03543	61.801435	63.196196
39	NM_00130325	ACAT2	acetyl-CoA acyltransferase	NP_00120182	94	100678				1101	1032	841	1293	1352	1166	9.977919	10.990262	9.458393	13.991147	13.765409
40	NM_001094	NI ASIC2	acid sensing ion channel	NP_001085.2	99	601784				0	0	0	0	0	0	0	0	0	0	0
41	NM_001095	NI ASIC1	acid sensing ion channel	NP_001086.2	100	602866				6368	5438	5329	4875	5178	4729	22.598168	22.778256	23.635671	21.023263	20.647201
43	NM_000665	NI ACHE	acetylcholinesterase	NP_000656.1	108	100740				38	31	34	22	43	36	0.176267	0.210342	0.216971	0.135803	0.244212
47	NM_001096	NI ACLY	ATP citrate lyase	NP_001087.2	115	108728				10438	9075	8409	9900	10423	9064	33.46322	34.284574	33.343292	37.930374	37.299663

[그림 3] RNA-seq 유전자 발현 Raw data 예시

2. 데이터 전처리

2.1 기술적 전처리

- RNA-seq 기반 유전자 발현 데이터(Expression count)에 대해 로그 변환($\log_2(x+1)$)을 수행하여 발현량 분포를 정규화함.
- 분석 신뢰도를 확보하기 위해 전체 샘플 중 발현 빈도가 낮은 유전자를 제거하고, 모델 학습에 의미 있는 유전자만을 선별함.
- 처리군(약물 처리)과 대조군(Control) 간 비교가 가능하도록 샘플 라벨을 정리하고, 유전자 × 샘플 행렬 형태로 데이터를 재구성함.
- 학습 데이터와 예측 데이터 간 유전자 구성이 일치하도록 유전자 정렬(alignment)을 수행하여 모델 입력 오류를 방지함.




2.2 변수 분포

- RNA-seq 기반 유전자 발현 데이터는 대부분의 유전자가 낮은 발현값(0 또는 매우 작은 count)에 집중되어 있으며, 소수의 유전자만이 높은 발현값을 가지는 우측 편향(right-skewed) 분포를 보임.
- 전체 유전자 중 약 85% 이상이 0~5 미만의 발현값 구간에 집중되어 있어, 원본 데이터를 그대로 사용할 경우 모델 학습 시 특정 고발현 유전자의 영향이 과도하게 반영될 가능성이 있음.
- 이러한 분포 특성으로 인해 데이터의 분산을 완화하고 극단값의 영향을 줄이기 위해 로그 변환($\log_2(x+1)$)을 적용하여 데이터 분포를 정규화함.
- 또한 발현 빈도가 극히 낮은 유전자는 생물학적 의미가 제한적일 수 있으므로, 저발현 유전자를 제거하여 노이즈를 감소시키고 모델의 안정성을 향상시킴



2.3 RNA-seq 발현 데이터의 샘플 분포 및 패턴 탐색


- PCA 분석을 통해 RNA-seq 유전자 발현 데이터의 전반적인 샘플 분포와 변동 패턴을 탐색함
 - 고차원 유전자 발현 데이터를 저차원 공간으로 축소하여 샘플 간 유사성과 차이를 시각적으로 확인하고자 함
- PCA 결과, 제1주성분(PC1)과 제2주성분(PC2)은 전체 발현 데이터 변동성의 상당 부분을 설명함
 - 샘플 간 유전자 발현 패턴 차이를 효과적으로 반영하고 있음을 확인함
- PCA 공간상에서 처리군과 대조군 샘플은 서로 다른 영역에 분포하는 경향을 보임
 - 실험 조건에 따라 유전자 발현 패턴이 체계적으로 변화하고 있음을 시사함
- 동일한 실험군 내 샘플들은 상대적으로 근접한 위치에 군집하는 양상을 보임
 - 샘플 간 발현 패턴의 일관성이 높고 실험 데이터의 신뢰도가 확보되었음을 의미함
- 이러한 결과는 RNA-seq 발현 데이터가 처리군과 대조군을 구분할 수 있는 정보를 충분히 포함하고 있음을 나타냄
 - 이후 예측 모델 학습을 위한 입력 데이터로서 활용 가능성이 높음을 시사함



[그림 6] RNA-seq 유전자 발현 데이터의 PCA 분석 결과

2.4 데이터 분포 최적화 및 정규화 확인

- 원본 RNA-seq 데이터의 우측 편향(Right-skewed)된 분포를 완화하기 위해 $\log_2(x+1)$ 변환을 적용함.
- 변환 후 데이터의 사분위수 및 평균 분포가 일정하게 정규화되었음을 확인하여, 특정 샘플에 의한 모델의 편향된 학습 가능성을 차단함.



[그림 7.] 데이터 필터링 및 변수 선택에 따른 데이터셋 규모 변화



[그림 8.] 유전자 발현량 데이터 전처리 현황 데이터 테이블

3. 모델링

3.1 모델링


- 전처리된 RNA-seq 유전자 발현 데이터를 기반으로 모델 입력 변수의 차원을 축소하고 노이즈를 제거하기 위해 feature selection을 수행함
- 본 과제에서는 Logistic Regression(L2 정규화) 기반 feature selection을 적용함
- L2 정규화는 유전자 간 상관관계(다중공선성)가 높은 RNA-seq 데이터 특성을 고려하여 특정 유전자에 과도한 가중치가 부여되는 것을 방지함
- 이를 통해 모델 학습에 기여도가 높은 핵심 유전자들을 선별하였으며, 이 결과는 이후 예측 모델의 입력 변수로 활용함

3.2 예측 모델 구축


- Feature selection을 통해 선별된 유전자 발현 데이터를 입력으로 Random Forest와 Logistic Regression을 결합한 Soft Voting 기반 분류 모델을 구축함
- Logistic Regression은 선형적 결정 경계를 기반으로 한 안정적인 분류를 제공하고, Random Forest는 비선형 패턴과 변수 간 상호작용을 효과적으로 학습함
- Soft Voting 방식을 적용하여 각 모델의 예측 확률값을 평균하여 최종 예측을 수행함으로써

단일 모델 대비 예측 안정성과 일반화 성능을 향상시킴

- Permutation test 결과, 실제 레이블을 사용한 모델의 정확도가 무작위 레이블 기반 분포 대비 현저히 높게 나타났다. 이는 구축된 예측 모델이 우연이 아닌 의미 있는 패턴을 학습했음을 시사함



[그림 9] 앙상블 학습 기반의 약물 반응 예측 모델 아키텍처 및 워크플로우



[그림 10] Random Forest와 Logistic Regression을 결합한 Soft Voting 기반 예측 모델 구조

3.3 성능 평가

3.3.1 교차 검증 기반 성능 평가

- LOOCV 기반 Accuracy, ROC-AUC를 산출하여 모델 성능을 평가하였고, 모든 샘플에 대해 정확한 분류가 이루어졌으며, Confusion Matrix 결과에서도 오분류가 발생하지 않음을 확인함



[그림 8] LOOCV 교차 검증 기반 분류 성능 평가 결과

3.3.2 Permutation Test 기반 예측 성능 검증


- Permutation test를 통해 실제 레이블 기반 정확도가 무작위 레이블 기반 분포 대비 유의하게 높음을 확인함.
- 이는 모델이 데이터의 우연적 패턴이 아닌 의미 있는 생물학적 신호를 학습했음을 시사함



[그림 9] Logistic Regression(L2) 모델의 Permutation Test를 통한 예측 성능 유의성 검증

3.3.3 예측 결과 및 확률 분포 분석

- 예측 결과에서 처리군(Treated)과 대조군(Control)이 명확히 구분되었으며, 각 샘플에 대해 예측 확률(probability)을 함께 제공함으로써 모델의 판단 신뢰도를 정량적으로 해석할 수 있음




[그림 10] 예측 모델 기반 처리군/대조군 분류 결과 및 예측 확률(proba) 분포

4. 중요도 및 기작 분석

4.1 핵심 유전자 중요도 분석


- L2 정규화 기반 로지스틱 회귀 모델을 통해 변별력이 높은 상위 300개의 핵심 유전자를 선별함.
- Heatmap 분석 결과, 처리군(Treated)과 대조군(Control) 사이에서 발현 패턴이 극명하게 대조되는 유전자 군집을 확인하였음.
- 주요 상위 유전자로 NCF2, TOMM40P4, MAPK8IP1P2, PKNOX2 등이 도출되었으며, 이는 약물 처리에 의한 특정 생물학적 반응을 강력하게 시사함.
- 특히 MAPK 관련 가부성 유전자(pseudogene)인 MAPK8IP1P2 등의 포함은 본 연구의 가설인 MAPK 신호 전달 경로 억제 기작과 밀접한 연관이 있는 것으로 판단됨.



[그림 11] 핵심 유전자 발현 차이에 대한 Heatmap 분석 결과

4.2 생물학적 기작(Pathway) 분석

- g:Profiler를 활용한 Enrichment 분석 결과, 유의미한 생물학적 경로가 다수 도출되었음.
- Keratin filament (GO:CC) 및 Cell periphery (GO:CC) 항목의 유의성이 높게 나타나, 약물 처리에 따른 세포 골격 재구조화(Cytoskeletal remodeling) 및 상피-간엽 이행(EMT) 관련 변화가 발생했음을 암시함.
- **Developmental process (GO:BP)**와 Arginine and proline metabolism (KEGG) 경로의 활성화는 약물에 의한 세포 분화 조절 및 대사 경로의 재편을 의미함



[그림 12.] g:Profiler를 이용한 기능적 강화(Enrichment) 분석 결과


5. 시각화

5.1 사용자 중심의 AI 분석 파이프라인 시각화

- 본 과제에서 구축한 AI 모델을 사용자가 쉽게 활용할 수 있도록 웹 기반 인터페이스로 구현하였음.
- 데이터 입력, AI 추론, 결과 시각화의 단계를 직관적으로 구성하여 비전문가도 NGS 데이터를 활용한 약물 반응 예측이 가능하도록 설계함.
- 사용자가 직접 환경 설정을 제어할 수 있도록 하여 다양한 분석 환경에 대응 가능하도록 설계함.
- 분석 효율성을 높이기 위해 데이터 캐시 관리 기능을 구현하였으며, 분석 결과를 팀 내에서 공유할 수 있는 인터페이스를 제공함.



[그림 16.] 최근 분석 이력 및 데이터셋 통계 정보 요약 인터페이스



[그림 17.] 분석 환경 설정 및 협업을 위한 통합 관리 시스템 인터페이스

6. 한계점 및 개선 방안

6.1 한계점

○ 통계적 유의성 확보의 어려움

- 수집된 샘플 수의 제한으로 인해 분석 결과의 p-value가 0.05 이상으로 산출되어, 통계적 유의성을 완벽히 확보하지 못하였음. 이는 모델의 예측 결과가 생물학적으로 우연일 가능성을 배제하기 어렵다는 점을 시사함

○ 데이터 관리 및 확장성 부족

- 현재 시스템은 외부 데이터베이스(DB)와 실시간 연동되지 않고 Streamlit 내에서 로컬 데이터를 처리하는 구조임. 따라서 대규모 데이터를 실시간으로 관리하거나 누적된 결과를 체계적으로 추적하는 데 한계가 있음.

○ 데이터 관리 및 확장성 부족

- 현재 시스템은 외부 데이터베이스(DB)와 실시간 연동되지 않고 Streamlit 내에서 로컬 데이터를 처리하는 구조임. 따라서 대규모 데이터를 실시간으로 관리하거나 누적된 결과를 체계적으로 추적하는 데 한계가 있음.

○ 피처 의존성 및 해석 제한

- 1,024차원의 Morgan Fingerprint에 비해 상대적으로 적은 수의 Descriptor(12개)를 사용하고 있어, 화학적 다양성을 충분히 설명하지 못했을 가능성이 존재함.

6.2 개선 방안

○ 데이터 증강 및 외부 DB 연동

- 공개된 RNA-seq 데이터베이스(GEO, TCGA 등)를 추가 확보하여 샘플 수를 늘림으로써 p-value의 유의성을 확보할 계획임. 또한, MySQL이나 MongoDB 등 외부 DB와 연동하여 분석 데이터의 영속성과 관리 효율성을 높이고자 함.

○ 모델 경량화 및 추론 최적화

- Random Forest와 Logistic Regression의 앙상블 구조를 유지하되, 핵심 피처를 추가로 압축하거나 모델 경량화 기법을 적용하여 예측 속도를 개선할 예정임.

○ 데이터 전처리 고도화

- 로그 변환 및 정규화 외에도 이상치 제거, 범주형 변환 등의 전처리 과정 적용

○ 분석 기작의 정교화

- g:Profiler 기반의 분석 외에도 추가적인 단백질-단백질 상호작용(PPI) 네트워크 분석 등을 결합하여, 통계적으로 다소 부족한 유의성을 생물학적 기작 근거로 보완하고자 함.

