

2025년도 나라별 행복도 예측과제 AI개발 수행내역서

과제명	AI기반 예측모델 개발 및 시각화
담당자	박OO

2025년 3월 19일

1. 사업과제 : AI기반 나라별 행복도 예측모델 개발 및 시각화

2. 개요 및 현황

2.1 추진배경 및 목적

- 유엔이 발표한 World Happiness Report(세계 행복 보고서)는 각 나라의 행복도를 평가하고, 그 배경에 있는 다양한 경제적, 사회적, 환경적 요인들을 분석하여 이를 세계에 공유하는 중요한 자료로 자리잡음
- AI 기술과 기계학습 모델은 방대한 데이터를 분석하고 예측할 수 있는 능력을 갖추고 있어, 나라별 행복도를 더욱 정교하게 예측할 수 있는 가능성을 제시
- 다양한 요인(예: GDP, 사회적 지원, 기대수명, 사회적 안정성 등)을 기반으로 각 나라의 행복도를 예측할 수 있는 기계학습 모델을 개발. 이를 통해 국가별 행복도를 예측하고, 이를 국가 정책과 연결할 수 있는 기반을 마련
- 예측된 행복도 결과를 바탕으로 각 나라가 자국의 행복도를 향상시키기 위해 어떤 요소에 집중해야 하는지 파악 할수 있음

2.2 과제 범위

과제구분		내용
AI	AI 기반 고객 이탈 예측모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 등 활용)
		예측모델 선정 및 학습
		RMSE, MAE 등 평가지표를 활용한 모델 성능 평가
		STREAMLIT 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 데이터 수집 및 관리의 용이성
- 이미 구축된 데이터베이스 활용 여부
- 종속변수에 영향을 미치는 다양한 독립변수에 대한 정보 포함 여부를 통한 모델 학습의 유용성

○ 예측모델 개발 효율성

- 모델 학습 및 평가 과정 간소화를 위한 다른 기초데이터에 비해 변수가 상대적으로 단순한 구조여부
- 개발된 모델을 통해 다른 기초데이터에 적용 가능 여부


○ 최종 목표 및 활용도

- 정확도 및 신뢰도: 예측 모델이 실제 행복도와 얼마나 근접하는지, 모델의 정확도를 평가하는 지표를 기준으로 데이터를 선정해야 합니다.
- 정책적 활용 가능성: 국가나 지역 차원에서 정책을 개선하기 위한 데이터 분석이 될 수 있도록, 정책 결정자들이 유용하게 활용할 수 있는 형태로 모델을 설계해야 합니다.

2) AI 예측 분석모델 적용 대상

구분	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
나라별 행복도	- 나라별, 년도별 정보 데이터 (2005~2022) - GDP, 사회지원 자유도 외에 핵심 변수가 포함된 데이터셋	- 나라변수 : 나라명, ISO코드 - 년도변수 : 년도 - 경제변수 : GDP - 사회변수 : 사회지원 등 - 국민인식변수 : 자유인식정도, 긍정, 부정적 영향 등	- 경제적, 사회적, 건강적 등 많은 요소들을 종합적으로 분석하여 각 국가의 행복도를 예측

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집

- Kaggle 13년간 나라별 행복도 데이터(CSV) : 2005년 ~2022년


A	B	C	D	E	F	G	H	I	J	K	L
Country name	iso alpha	year	Happiness score	Log GDP per capita	Social support	Healthy life expectancy	Freedom to choose	Generosity	Perceptions of corruption	Positive affect	Negative affect
Afghanistan	AFG	2008	3.724	7.35	0.451	50.5	0.718	0.168	0.882	0.414	0.258
Afghanistan	AFG	2009	4.402	7.509	0.552	50.8	0.679	0.191	0.85	0.481	0.237
Afghanistan	AFG	2010	4.758	7.614	0.539	51.1	0.6	0.121	0.707	0.517	0.275
Afghanistan	AFG	2011	3.832	7.581	0.521	51.4	0.496	0.164	0.731	0.48	0.267
Afghanistan	AFG	2012	3.783	7.661	0.521	51.7	0.531	0.238	0.776	0.614	0.268
Afghanistan	AFG	2013	3.572	7.68	0.484	52	0.578	0.063	0.823	0.547	0.273
Afghanistan	AFG	2014	3.131	7.671	0.526	52.3	0.509	0.106	0.871	0.492	0.375
Afghanistan	AFG	2015	3.983	7.654	0.529	52.6	0.389	0.082	0.881	0.491	0.339
Afghanistan	AFG	2016	4.22	7.65	0.559	52.925	0.523	0.044	0.793	0.501	0.348
Afghanistan	AFG	2017	2.662	7.648	0.491	53.25	0.427	-0.119	0.954	0.435	0.371
Afghanistan	AFG	2018	2.694	7.631	0.508	53.575	0.374	-0.091	0.928	0.385	0.405
Afghanistan	AFG	2019	2.375	7.64	0.42	53.9	0.394	-0.106	0.924	0.324	0.502
Afghanistan	AFG	2021	2.436	7.324	0.454	54.55	0.394	-0.081	0.946	0.179	0.607
Afghanistan	AFG	2022	1.281		0.228	54.875	0.368		0.733	0.206	0.576
Albania	ALB	2007	4.634	9.122	0.821	66.76	0.529	-0.01	0.875	0.489	0.246
Albania	ALB	2009	5.485	9.241	0.833	67.32	0.525	-0.159	0.864	0.564	0.279
Albania	ALB	2010	5.269	9.283	0.733	67.6	0.569	-0.174	0.726	0.576	0.3
Albania	ALB	2011	5.867	9.311	0.759	67.88	0.487	-0.206	0.877	0.566	0.257
Albania	ALB	2012	5.51	9.326	0.785	68.16	0.602	-0.17	0.848	0.553	0.271
Albania	ALB	2013	4.551	9.338	0.759	68.44	0.632	-0.129	0.863	0.541	0.338
Albania	ALB	2014	4.814	9.358	0.626	68.72	0.735	-0.026	0.883	0.573	0.335
Albania	ALB	2015	4.607	9.383	0.639	69	0.704	-0.082	0.885	0.579	0.35
Albania	ALB	2016	4.511	9.417	0.638	69.025	0.73	-0.019	0.901	0.567	0.322
Albania	ALB	2017	4.64	9.455	0.638	69.05	0.75	-0.031	0.876	0.547	0.334
Albania	ALB	2019	5.004	9.407	0.684	69.075	0.694	0.007	0.890	0.500	0.310

- Kaggle 2023 나라별 행복도 데이터(CSV) : 2023년


Country name	iso alpha	year	Happiness score	Log GDP per capita	Social support	Healthy life expectancy	Freedom to choose	Generosity	Perceptions of corruption	Positive affect	Negative affect
Afghanistan	AFG	2023	1.859	7.324	0.341	54.712	0.382	-0.081	0.847		
Albania	ALB	2023	5.277	9.567	0.718	69.15	0.794	-0.007	0.878		
Algeria	DZA	2023	5.329	9.3	0.855	66.549	0.571	-0.117	0.717		
Argentina	ARG	2023	6.024	9.959	0.891	67.2	0.823	-0.089	0.814		
Armenia	ARM	2023	5.342	9.615	0.79	67.789	0.796	-0.155	0.705		
Australia	AUS	2023	7.095	10.821	0.934	71.05	0.89	0.198	0.496		
Austria	AUT	2023	7.097	10.899	0.888	71.15	0.855	0.102	0.497		
Bahrain	BHR	2023	6.173	10.776	0.844	65.825	0.944	0.117	0.737		
Bangladesh	BGD	2023	4.282	8.685	0.544	64.548	0.845	0.005	0.698		
Belgium	BEL	2023	6.859	10.844	0.915	70.899	0.825	0.001	0.549		
Benin	BEN	2023	4.374	8.103	0.437	56.095	0.743	-0.043	0.576		
Bolivia	BOL	2023	5.684	8.985	0.811	63.599	0.868	-0.063	0.846		
Bosnia and Herzegovina	BIH	2023	5.633	9.616	0.88	67.275	0.746	0.206	0.918		
Botswana	BWA	2023	3.435	9.629	0.753	54.725	0.742	-0.215	0.83		
Brazil	BRA	2023	6.125	9.582	0.836	65.749	0.801	-0.009	0.738		
Bulgaria	BGR	2023	5.466	10.087	0.918	66.5	0.801	-0.057	0.911		
Burkina Faso	BFA	2023	4.638	7.667	0.663	55.461	0.696	0.095	0.771		
Cambodia	KHM	2023	4.393	8.385	0.747	61.9	0.958	0.073	0.857		
Cameroon	CMR	2023	4.973	8.217	0.686	55.847	0.686	0.015	0.846		
Canada	CAN	2023	6.961	10.773	0.929	71.4	0.874	0.153	0.42		
Chad	TCO	2023	4.397	7.261	0.722	53.125	0.677	0.221	0.807		
Chile	CHL	2023	6.334	10.114	0.889	70.3	0.792	-0.011	0.823		
China	CHN	2023	5.818	9.738	0.836	68.689	0.882	-0.041	0.727		
Colombia	COL	2023	5.63	9.584	0.822	69.35	0.804	-0.104	0.834		
Comoros	COM	2023	3.545	8.075	0.471	59.425	0.47	-0.014	0.727		
Congo (Brazzaville)	COG	2023	5.267	8.095	0.605	56.85	0.73	-0.004	0.739		
Congo (Kinshasa)	COD	2023	3.207	7.007	0.652	55.375	0.664	0.086	0.834		
Costa Rica	CRI	2023	6.609	9.952	0.872	70	0.895	-0.07	0.768		
Croatia	HRV	2023	6.405	10.004	0.847	68.075	0.757	0.000	0.605		

2. 데이터 분석

2.1-1 독립변수와 Happiness score(행복도)의 상관관계(Heatmap)



2.1-2 독립변수와 Happiness score(행복도)의 중요도(Feature Importance)



○ EDA히스토그램, Feature_importance, Heatmap 변수별 분포를 통해 정규분포 여부 및 변수 간 관계를 유추

○ 행복도에 영향을 미치는 요인 분석

■ GDP, 긍정적.부정적 영향, 사회적지원, 기대수명, 자유인식, 부패인식, 관대함 수준

○ 나라별 행복도 예측 모델링을 위한 대상 설정 : GDP, 사회적지원, 기대수명, 자유인식정도

2.2 탐색적 데이터 분석

○ 결측치 및 중복값 통계

- 전체 데이터 : 2199(100%), 결측 데이터 : 73건(0.3%), 중복 데이터 : 0건(0%)

Overview	Alerts 14	Reproduction
Dataset statistics		Variable types
Number of variables	13	Text 2
Number of observations	2199	Numeric 11
Missing cells	73	
Missing cells (%)	0.3%	
Duplicate rows	0	
Duplicate rows (%)	0.0%	
Total size in memory	458.1 KiB	
Average record size in memory	213.3 B	

○ 주요 변수별 데이터 분포(Histogram)

- GDP(Log GDP per capita)

■ 요약 : 평균-9.389, 최소값-5.527, 최대값-11.664

■ 데이터는 약간 오른쪽으로 치우치고 웨이브적인 분포를 보인다. 9,11정도 값의 비율이 높다


■ 10정도의 값이 분포가 주위보다 낮은 특이점을 가지고 있다

Log GDP per capita

Real number (ℝ)

High correlation

Distinct	1653	Minimum	5.527
Distinct (%)	75.2%	Maximum	11.664
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	9.3897604	Memory size	17.3 KiB



- 사회적 지원(Social support)

■ 요약 : 평균-0.81, 최소값-0.228, 최대값-0.987


■ 데이터는 오른쪽으로 치우친 분포를 보인다. 0.9전,후 정도 값의 비율이 높다

Social support

Real number (ℝ)

High correlation

Distinct	478	Minimum	0.228
Distinct (%)	21.7%	Maximum	0.987
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	0.81068115	Memory size	17.3 KiB



- 기대수명(Healthy life expectancy at birth)


- 요약 : 평균-63.294, 최소값-6.72, 최대값-74.475
- 데이터는 오른쪽으로 치우친 분포를 보인다. 70~75정도 값의 비율이 높다

Healthy life expectancy at birth

Real number (ℝ)

High correlation

Distinct	1108	Minimum	6.72
Distinct (%)	50.4%	Maximum	74.475
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	63.294582	Memory size	17.3 KiB



- 자유에대한 인식(Healthy life expectancy at birth)


- 요약 : 평균-0.748, 최소값-0.258, 최대값-0.985
- 데이터는 오른쪽으로 치우친 분포를 보인다. 0.7~0.9정도 값의 비율이 높다

Freedom to make life choices

Real number (ℝ)

High correlation

Distinct	545	Minimum	0.258
Distinct (%)	24.8%	Maximum	0.985
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	0.74784718	Memory size	17.3 KiB



- 그 외 관대함수준(Generosity) 나 긍정적 영향(Positive affect) 등이 정규분포를 하고 있지만 위에 중요도에서 낮은 수치를 가지고 있어 이렇게 4개를 중요한 변수로 생각함.

○ 데이터 전처리

- 결측치 : fillna를 사용하여 평균값으로 대체

First rows

Last rows

year	Happiness score	Log GDP per capita	Social support	Healthy life expectancy at birth	Freedom to make life choices	Generosity	Perceptions of corrup
2013	4.69	7.75	0.80	48.80	0.58	-0.09	0.83
2014	4.18	7.75	0.77	50.00	0.64	-0.06	0.82
2015	3.70	7.75	0.74	51.20	0.67	-0.11	0.81
2016	3.73	7.74	0.77	51.67	0.73	-0.08	0.72
2017	3.64	7.75	0.75	52.15	0.75	-0.08	0.75
2018	3.62	7.78	0.78	52.62	0.76	-0.05	0.84
2019	2.69	7.70	0.76	53.10	0.63	-0.05	0.83

2. 데이터 학습 및 모델정의

3.1 모델 정의

- 머신러닝 모델 선택 : RandomForestRegressor

```
feature_names = ['year',
                  'Log GDP per capita',
                  'Social support',
                  'Healthy life expectancy at birth',
                  'Freedom to make life choices',
                  'Generosity',
                  'Perceptions of corruption',
                  'Positive affect',
                  'Negative affect'] + [col for col in df_en.columns if col.startswith('nn_')]
X = df_en[feature_names[0:9]]
y = df_en['Happiness score']

# 데이터 분할
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

rf_model = RandomForestRegressor(random_state=42)
```

- 하이퍼 파라미터 최적화 모델 정의 (GridSearchCV 사용)

- 트리 개수 : 300, 깊이 : 16, 최소 샘플 값 : 2

```
# 하이퍼파라미터 튜닝 GridSearchCV 사용
param_grid = {
    'n_estimators': [50,100,200,300],
    'max_depth': [4,6,8,10,12,14,16,18,20],
    'min_samples_split': [2,4,8,16]
}

# 모델 학습
# 최적의 모델 저장
grid_search = GridSearchCV(estimator=rf_model, param_grid=param_grid, cv=3)
grid_search.fit(X_train, y_train)
best_rf_model = grid_search.best_estimator_
print("Best Param:", grid_search.best_params_)
# rf_model = RandomForestRegressor(random_state=42, n_estimators=200, max_depth=14, min_samples_split=2)
# rf_model.fit(X_train, y_train)

✓ 7m 38.2s
```

Best Param: {'max_depth': 16, 'min_samples_split': 2, 'n_estimators': 300}

3.2 모델학습 및 학습 시각화

- 모델 학습 및 예측(성능평가)

```
# 예측
rf_pred = rf_model.predict(X_test)
# rf_pred = best_rf_model.predict(X_test)


# 성능 평가
rf_mse = mean_squared_error(y_test, rf_pred)
rf_rmse = root_mean_squared_error(y_test, rf_pred)
rf_mae = mean_absolute_error(y_test, rf_pred)
rf_r2 = r2_score(y_test, rf_pred)
print(f"MSE: {rf_mse:.2f}")
print(f"RMSE: {rf_rmse:.2f}")
print(f"MAE: {rf_mae:.2f}")
print(f"R2: {rf_r2:.2f}")

✓ 0.0s
```

MSE: 0.15
RMSE: 0.39
MAE: 0.28
R2: 0.87


○ 트리개수($n_{\text{estimators}}$)에 대한 성능평가

- 트리개수($n_{\text{estimators}}$)가 너무 많으면 계산량이 증가해 느려질 수 있음



○ 트리의 깊이에 대한 성능평가

- 트리의 깊이가 깊을수록 훈련 성능은 좋아지지만, 과적합 위험도 커짐
- 테스트 RMSE가 증가하면 과적합 신호일 가능성이 높음




3.3 모델 예측

○ 예측값 vs 실제값 비교(테스트 데이터)

- 우상향 그래프가 나옴

```
# 실제값과 예측값 비교 시각화 (테스트 데이터 기준)
#print(rf_pred)
plt.figure(figsize=(10, 6))
plt.subplot(2, 1, 1)
plt.scatter(y_test, rf_pred, alpha=0.5)
plt.plot([y_test.min(), y_test.max()],
         [y_test.min(), y_test.max()],
         'r--', lw=2)
plt.xlabel('실제 만족도')
plt.ylabel('예측 만족도')
plt.title('행복도 실제값 vs 예측값 (테스트 데이터)')
plt.grid(True)
plt.tight_layout()
#%matplotlib inline
plt.show()
plt.savefig("report/output.png")
```




○ 년도별 예측값과 실제값 비교

- 년도별 전체 나라의 행복도를 평균을 내어 실제값과 예측값을 비교함

```
# 년도별 행복 점수 시각화 함수
def plot_happiness_by_year(df, year_column, actual_column, predicted_column):
    plt.figure(figsize=(10, 6))

    df_grouped = df.groupby(year_column)[[actual_column, predicted_column]].mean()

    df_grouped.plot(kind='bar', figsize=(12, 6), alpha=0.7)
    plt.xlabel("년도")
    plt.ylabel("행복도")
    plt.title("실제값, 예측값 년도별 행복도 비교")
    plt.legend(["실제값", "예측값"])
    plt.xticks(rotation=45)
    plt.show()
```



○ 특정 국가에서 년도별 예측값과 실제값 비교


- 나라 이름으로 년도별 예측값과 실제값을 비교함
- 형태는 대부분 그대로 따라가나 차이가 좀 있는 년도가 보임

```
# 국가별 행복 점수 시각화 함수
def plot_happiness_by_country(df, country_column, year_column, actual_column, predicted_column, country_name):
    plt.figure(figsize=(10, 6))

    df_country = df[df[country_column] == country_name]
    df_country = df_country.sort_values(by=year_column)

    plt.plot(df_country[year_column], df_country[actual_column], marker='o', linestyle='-', label="Actual", color='blue')
    plt.plot(df_country[year_column], df_country[predicted_column], marker='s', linestyle='--', label="Predicted", color='orange')

    plt.xlabel("년도")
    plt.ylabel("행복도")
    plt.title(f"{country_name}의 년도별 예측값, 실제값 비교")
    plt.legend()
    plt.grid(True)
    plt.show()
```



1. 프로토타이핑(화면)

4.1 모델 예측

○ 두 국가의 행복도 예측

- 첫 번째 국가

- 입력 > 국가명 : Afghanistan, 년도 : 2025년, 인당GDP : 5.00, 사회적지원 : 0.9, 기대수명 : 75, 자유인식도 : 0.8 등

- 예측 > 행복도 점수 : 5.42

- 두 번째 국가

- 입력 > 국가명 : South Korea, 년도 : 2025년, 인당GDP : 20.00, 사회적지원 : 1.0, 기대수명 : 90, 자유인식도 : 0.9 등

- 예측 > 행복도 점수 : 6.69

첫번째 국가 행복도 예측 두번째 국가 행복도 예측 두 국가 행복도 비교

국가 행복도 예측

두 번째 나라를 선택하세요:

South Korea	▼
년도	
2025	- +
인당GDP	
20.00	- +
사회적지원	
1.00	- +
기대수명	
90	- +
자유인식	
0.90	- +
관대함	
0.50	- +
부패예대항인식	
0.10	- +
긍정적영향	
0.80	- +
부정적영향	
0.10	- +

South Korea의 예측된 행복도 점수: 6.69

첫번째 국가 행복도 예측 두번째 국가 행복도 예측 두 국가 행복도 비교

국가 행복도 예측

나라를 선택하세요:

Afghanistan	▼
년도	
2025	- +
인당GDP	
5.00	- +
사회적지원	
0.90	- +
기대수명	
75	- +
자유인식	
0.80	- +
관대함	
0.20	- +
부패예대항인식	
0.10	- +
긍정적영향	
0.80	- +
부정적영향	
0.10	- +

Afghanistan의 예측된 행복도 점수: 5.42

○ 예측한 두 국가의 행복도 비교

첫번째 국가 행복도 예측 두번째 국가 행복도 예측 두 국가 행복도 비교

두 국가 행복도 비교

